

Wahrscheinlichkeitstheorie – Grundzüge der Statistik

Holger Jäkel



- Grundzüge der Statistik
 - Motivation und Modellierung
 - Punktschätzer
 - Konfidenzintervalle
 - Deskriptive Statistik
 - Hypothesentests
 - Abschließende Bemerkungen
 - Lernziele
 - Literatur

- Die folgenden Betrachtungen diskutieren grundlegende Verfahren der Statistik aus dem Bereich Modellbildung, Schätzer und Testtheorie.
- Die Illustration erfolgt anhand einfacher Beispiele. Die volle Bedeutung der Methoden zur Behandlung „echter ETIT/MEDT/MIT-praktischer Fragestellungen“ wird oft erst in späteren Vorlesungen deutlich, wenn die entsprechenden Fragestellungen diskutiert werden.
- Grundsätzliches Ziel ist immer die Bestimmung/Schätzung unbekannter Parameter, die Analyse von Abhängigkeiten, das Anpassen eines Signalmodells an Messungen, ...
- Wie so oft, streben wir in „unserer WT“ nicht unbedingt bedingungslose mathematische Strenge an, sondern versuchen eine Mischung aus Korrektheit, Anschaulichkeit und Übertragbarkeit auf praktische Problemstellungen. Ob das gelungen ist, mögen Sie beurteilen...

- Dieses Kapitel dient als Vorbereitung für spätere Anwendung in vielerlei Disziplinen, etwa:
 - Bestimmung von Parametern wie Mittelwert, Median, Varianz, ...
 - Tests auf Unkorreliertheit oder Unabhängigkeit
 - Bestimmen oder Anpassen von Verteilungen einer Messung: modelling, distribution fitting

- Genannt seien hier beispielsweise folgende Methoden des Ingenieuralltags:
 - Parameterschätzung
 - Konfidenzintervalle
 - Varianzanalyse
 - Regression
 - u.v.a.m.

■ Beispiele: (MEDT)

- Referenzwerte/Normalwerte von Laborwerten: Meist^{1 2} ist dies der Bereich $[x_{0,025}, x_{0,975}]$ („95% der Personen liegen dazwischen“)
- Nebenwirkungen bei Medikamenten: „selten“ bedeutet³ bei 0,01 – 0,1% der Personen, „gelegentlich“ bedeutet 0,1 – 1% der Personen

■ Beispiele: (ETIT)

- Ausfallanalyse von Bauteilen und Systemen
- Bestimmung eines geeigneten Modells für Störeinflüsse: Kann man eine Gaußverteilung annehmen?

■ Beispiele: (Alltag)

- Wie entstehen Wahlprognosen? Wie viele Personen müssen befragt werden?
- Wie werden Tarife bei Lebensversicherung, Rente, Kfz, ..., berechnet?


¹Quelle: <https://www.stiftung-gesundheitswissen.de/gesund-es-leben/koerper-wissen/laborwerte-richtig-verstehen>

²... Sie erinnern sich an Quantile...?!

³Quelle: <https://de.wikipedia.org/wiki/Nebenwirkung>

■ Beispiele: (Alltag)⁴

- Sterbetafeln in Grafik überführt; „einjährige Sterbewahrscheinlichkeiten“



⁴Quelle: https://www.destatis.de/DE/Themen/Gesellschaft-Umwelt/Bevoelkerung/Sterbefaelle-Lebenserwartung/Tabellen/_tabellen-innen-lebenserwartung-sterbetafel.html

- Folgende Diskussionen orientieren sich an

[Hen95]: N. Henze, *Stochastik I – Einführung in die Wahrscheinlichkeitstheorie und Statistik*, Skript Universität Karlsruhe (TH), 1995

[Hen17]: N. Henze, *Stochastik für Einsteiger – Eine Einführung in die faszinierende Welt des Zufalls*, 11. Auflage, Springer, 2017

[Bo94]: K. Bosch, *Elementare Einführung in die angewandte Statistik*, Vieweg, 1994

- Zufallsvariablen werden durch Großbuchstaben gekennzeichnet: X
- Eine Folge von Zufallsvariablen ist entsprechend $(X_i)_{i \in \mathbb{N}}, (X_i)_{i=1}^{\infty}$
- Vektoren von Zufallsvariablen verwenden einen fettgedruckten Großbuchstabe: $\mathbf{X} = (X_1, \dots, X_N)$
- Realisierungen von Zufallsvariablen sind durch Kleinbuchstaben kenntlich gemacht: $X = x$
- Vektoren von Realisierungen verwenden einen fettgedruckten Kleinbuchstaben: $\mathbf{X} = \mathbf{x} = (x_1, \dots, x_N)$
- Soll bei Zufallsvektoren oder Realisierungen die Abhängigkeit von der Beobachtungslänge betont werden, so schreibt man auch $\mathbf{X}^{(N)}$ oder $\mathbf{x}^{(N)}$

- Die Abkürzung *iid* steht für „independent and identically distributed“ und beschreibt die Tatsache, dass die Komponenten $X_1, X_2, \dots$ einer Folge/eines Vektors stochastisch unabhängig sind und dieselbe Verteilung besitzen.
- Diese iid Komponenten entsprechen unabhängigen Messwerten.
- Hierzu muss in der Praxis sichergestellt werden, dass die Messungen/Beobachtungen auch wirklich unabhängig sind!

- Gelegentlich verwendet die Literatur⁵ und auch diese Vorlesung die abkürzende Schreibweise:

$$[a : b] := \{a, a + 1, \dots, b - 1, b\}, \quad a, b \in \mathbb{Z}, a < b$$

sowohl für Mengen als auch für Teile eines Vektors/Tupels. Damit wäre beispielsweise:

$$[1 : N] = \{1, 2, \dots, N\}$$

$$\mathbf{X}_{[1:N]} = (X_1, \dots, X_N)$$

$$[2 : 5] = \{2, 3, 4, 5\}$$

$$\mathbf{x}_{[2:5]} = (x_2, x_3, x_4, x_5)$$

⁵Teilweise kennt man dies vielleicht als „Slicing“, z.B. aus Python oder Matlab.

■ Motivation:

- Oft ergeben sich in der Modellierung stochastische Modelle mit unbekannten (deterministischen) Parametern
- Ziel ist dann die Bestimmung gesuchter (deterministischer) Größen aus zufälligen Beobachtungen

■ Beispiele:

- 1 „Bernoulli-Experiment“: Durchführen von N Bernoulli-Versuchen mit unbekannter, aber fester „Trefferwahrscheinlichkeit“ $\rightarrow$ Verteilung $\text{Bin}(N, p)$ mit unbekanntem, aber festem p , welches bestimmt werden soll.
- 2 „Temperatur-Messung“: Durch Störung überlagerte („verrauschte“) Beobachtungen $\rightarrow$ das Modell lautet $Y = b + Z$ mit $Z \sim f_Z(z)$ und unbekanntem, aber festem $b \in \mathbb{R}$, welches bestimmt werden soll.
- 3 „Taxi-Problem“: Schätze eine unbekannte Anzahl der Elemente in einer Grundgesamtheit anhand deren Signatur, z.B. numerierte Taxen

■ Kommentar:

- In manchen Modellierungen kann zudem eine Verteilung auf den möglichen Parameterwerten ergänzt werden.
- Der Parameter ist zwar nach wie vor unbekannt, gewisse Werte sind jedoch „plausibler“ als andere.
- Entsprechendes Vorwissen kann hilfreich sein.
- Derartige Betrachtungen sind vorläufig Zukunftsmusik...:

Bis auf Weiteres wird der gesuchte Parameter zur einfacheren Betrachtung als unbekannt, aber fest angenommen!

■ Modellbildung:

- Gegeben sind im Folgenden stets Zufallsvariablen

$$X_i : (\Omega, \mathcal{B}, P) \rightarrow (\mathcal{X}, \mathcal{B}(\mathcal{X})), \quad i \in [1 : N]$$

Der Zielraum ist in dieser Vorlesung reellwertig $\mathcal{X} \subseteq \mathbb{R}$. Es wird dennoch $\mathcal{X}$ verwendet, um an einigen Stellen deutlich machen zu können, wenn/dass eine Zufallsvariable diskret bzw. stetig ist.

- Die *Verteilung* von X_i ist durch einen Wert $\vartheta \in \Theta$ parametrisiert:

$$X_i \sim P_{\vartheta}, \quad i \in [1 : N]$$

- Zur Vereinfachung der Notation wird angenommen, dass $\Theta \subseteq \mathbb{R}$ eindimensional ist!



- Es werden Realisierungen von mehrfachen Beobachtungen betrachtet:

$$\mathbf{X} = (X_1, \dots, X_N) = (x_1, \dots, x_N) = \mathbf{x} \in \mathcal{X}^N$$

- Ziel ist die Bestimmung des unbekannten, aber festen Parameters $\vartheta \in \Theta$ aus der mehrfachen Beobachtung $\mathbf{x}$

Definition

Eine Beobachtung bzw. Stichprobe $x \in \mathcal{X}^N$ heißt *einfache Stichprobe* oder *einfache Beobachtung*, falls die Komponenten in

$$\mathbf{X} = (X_1, \dots, X_N) = (x_1, \dots, x_N) = \mathbf{x} \in \mathcal{X}^N$$

unabhängig und identisch verteilt sind.

Dies wird in Anlehnung an die englische Bezeichnung *independent and identically distributed* auch als *iid* bezeichnet.

Sofern nichts anderes gesagt wird, gehen wir im Folgenden von einer einfachen Stichprobe aus. Praktisch muss hierzu sichergestellt werden, dass die einzelnen Realisierungen auch wirklich unabhängig⁶ sind!

⁶ **Beispiel:** Umfragen bei Wahlen: Wer wird gefragt? Wann erfolgt die Umfrage? ...

■ Beispiel: (Bernoulli-Experiment)

- Die Modellannahme lautet $X_i \sim \text{Bernoulli}(p)$, $i \in [1 : N]$ mit *unbekannter Trefferwahrscheinlichkeit*

$$p = P(X_i = 1)$$

- Somit ist hier $\mathcal{X} = \{0, 1\}$.
- Mehrfache Beobachtung liefert den Beobachtungsvektor (noch stochastisch, keine Realisierung)

$$\mathbf{X} = (X_1, \dots, X_N) \in \{0, 1\}^N$$

- „Bauchgefühl“: Je mehr Treffer ($X_i = 1$) in einer Stichprobe der Länge N sind, desto größer ist vermutlich p

■ **Beispiel:** (Bernoulli-Experiment) (ctd.)

- „Bauchgefühl++“: Definiere die Anzahl an Treffern in der Beobachtung $\mathbf{X} = \mathbf{x}$ durch

$$\sum_{i=1}^N \mathbb{1}\{x_i = 1\} = \sum_{i=1}^N x_i.$$

Damit könnte man vermuten⁷, dass für große N

$$p \approx \frac{1}{N} \sum_{i=1}^N x_i$$

gilt, also die Wahrscheinlichkeit ungefähr der relativen Häufigkeit entspricht.

⁷**Übung:** Können Sie das mit Ihren bisherigen WT-Kenntnissen begründen?

■ **Beispiel:** (Temperaturmessung)

- Die Modellannahme lautet

$$X_i = b + Z_i, \quad Z_i \sim f_Z(z), \quad i \in [1 : N]$$

mit *unbekanntem Parameter* $b \in \mathbb{R}$

- Somit ist hier $\mathcal{X} = \mathbb{R}$.
- Mehrfache Beobachtung liefert den Beobachtungsvektor (noch stochastisch, keine Realisierung)

$$\mathbf{X} = (X_1, \dots, X_N) \in \mathbb{R}^N$$

- Sind die Störungen Z_i unabhängig, so folgt:

$$f_{\mathbf{X}}(x_1, \dots, x_N) = \prod_{i=1}^N f_{X_i}(x_i)$$

■ Beispiel: (Temperaturmessung) (ctd.)

- „Bauchgefühl++“: Sind die Störungen Z_i mittelwertfrei, $\mathbb{E}(Z_i) = 0$, und definiert man den Mittelwert der Beobachtung durch

$$\frac{1}{N} \sum_{i=1}^N x_i,$$

so könnte man vermuten, dass

$$b \approx \frac{1}{N} \sum_{i=1}^N x_i$$

gilt und „sich das Rauschen bzw. die Störung herausmittelt“.⁸

⁸Ein praktisch sehr gängiger und oft hilfreicher Ansatz, sofern das Rauschen tatsächlich mittelwertfrei ist.

■ Beispiel: (Taxi-Problem)

- Die Modellannahme lautet $X_i \sim \mathcal{U}[1 : K]$ als Gleichverteilung auf der Menge $[1 : K]$ mit *unbekannter Elementanzahl* K
- Somit ist hier $\mathcal{X} = \{1, 2, \dots, K\}$.
- Mehrfache Beobachtung liefert den Beobachtungsvektor (noch stochastisch, keine Realisierung)

$$\mathbf{X} = (X_1, \dots, X_N) \in [1 : K]^N$$

- „Bauchgefühl++“: Wähle größten beobachteten Wert gemäß

$$K \stackrel{?}{\approx} \max_{1 \leq i \leq N} x_i$$

Hinweis



Eine möglichst exakte Modellbildung ist für die erfolgreiche Anwendung aller folgenden Methoden von zentraler Bedeutung!

Bei Verwendung eines falschen bzw. nicht passenden Modells werden die im Folgenden diskutierten Methoden/Algorithmen Ergebnisse liefern. Dieser ergeben allerdings ggf. nur wenig/keinen Sinn.

Beachte



In den *bisherigen Kapiteln* haben wir uns damit beschäftigt, *Wahrscheinlichkeiten der Form $P(X = x)$ zu berechnen*. Normalerweise war hier das Modell bekannt oder dessen Formulierung war Teil der Aufgabe und die Lösung bestand „lediglich darin vorwärts zu rechnen“.

Bei Schätzungen und Statistik ist die Situation anders: Hier ist eine mehrfache Beobachtung gegeben (!), etwa $X = x$, und man versucht, den dahinterliegenden *Zufallsmechanismus zu identifizieren*, der x erzeugt hat!

Definition




Ein *statistisches Modell* besteht aus einer Beobachtungsmenge⁹ $\mathcal{X}$ und einer parametrisierten Familie von Wahrscheinlichkeitsverteilungen $(P_{\vartheta})_{\vartheta \in \Theta}$ auf $\mathcal{X}$. Meist ist in dieser Vorlesung $\Theta \subseteq \mathbb{R}$.

Jedes $\vartheta \in \Theta$ beschreibt eine andere Verteilung P_{ϑ} mit entsprechenden stochastischen Eigenschaften wie etwa Erwartungswert $\mathbb{E}_{\vartheta}(\cdot)$, Varianz $\mathbb{V}_{\vartheta}(\cdot)$ etc. → **Ziel:** Bestmögliche Bestimmung von ϑ !

⁹Die σ -Algebra $\mathcal{B}(\mathcal{X})$ wird im Folgenden als $\mathcal{B}(\mathcal{X}) = \mathcal{P}(\mathcal{X})$ bzw. $\mathcal{B}(\mathcal{X}) = \mathcal{B}(\mathbb{R})$ für diskrete bzw. stetige Zufallsvariablen angenommen und nicht mehr explizit aufgeführt.

■ Beispiel:

- Die Modellannahme sei $X_i \sim \mathcal{N}(\vartheta, \sigma^2 = 1/2)$ mit unbekanntem $\vartheta \in \Theta = \{0, 2, 4, 6, 8, 10\}$.
- Die entsprechenden Dichten sind in der folgenden Abbildung dargestellt.



- **Frage:** Welcher der möglichen Verteilungen entstammen die roten Beobachtungen X?

■ Bemerkungen:

- Stetige bzw. diskrete Verteilungen P_{ϑ} werden durch ihre Wahrscheinlichkeitsdichten¹⁰ bzw. durch ihre Wahrscheinlichkeitsmassenfunktionen¹¹ beschrieben:

$$f_{\vartheta}(x) \quad \text{bzw.} \quad p_{\vartheta}(x)$$

- Beachte: Pdf und pmf sind Verteilungen und müssten (im WT-Sinne) eigentlich als $f_{X,\vartheta}(x)$ bzw. $p_{X,\vartheta}(x)$ geschrieben werden. Zur Vereinfachung wird der zusätzliche Index weggelassen.
- Ebenfalls gebräuchlich ist eine Schreibweise, in welcher der Parameter ϑ nicht als tiefgestellter Index, sondern als feststehende, aber unbekannte Bedingung dargestellt wird; etwa:

$$f(x|\vartheta) \quad \text{bzw.} \quad p(x|\vartheta)$$

¹⁰ **Erinnerung:** Abkürzung pdf

¹¹ **Erinnerung:** Abkürzung pmf

■ Beispiel: (Bernoulli-Experiment)

- Die Modellannahme lautet $X_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\vartheta)$, $i \in [1 : N]$ mit *unbekannter Trefferwahrscheinlichkeit*

$$\vartheta = P(X_i = 1) \in [0, 1] = \Theta.$$

- Damit ergibt sich für jeden Beobachtungsvektor $\mathbf{x}$ die pmf¹²

$$p_{\vartheta}(\mathbf{x}) = \vartheta^n (1 - \vartheta)^{N-n}$$

mit

$$n := \sum_{i=1}^N x_i$$

¹²Übung: Wieso „fehlt der gewohnte Binomialkoeffizient“?

■ Beispiel: (Temperaturmessung)

- Die Modellannahme lautet $X_i = \vartheta + Z_i, i \in [1 : N]$ mit *unbekannter Konstanten* („Temperatur“)

$$\vartheta \in \mathbb{R} = \Theta$$

- Ist beispielsweise $Z_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$, so folgt¹³ $X_i \stackrel{\text{iid}}{\sim} \mathcal{N}(\vartheta, \sigma^2)$ mit unbekanntem Erwartungswert.
- Damit ergibt sich für jeden Beobachtungsvektor die pdf

$$f_{\vartheta}(\mathbf{x}) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \vartheta)^2}{2\sigma^2}\right).$$

¹³**Übung:** Nachweis; Ansatz wie gewohnt: $P(X_i \leq x_i) = \dots$ und Ableiten, um zu zeigen, dass sich in jeder Komponenten die obige Dichte ergibt.

■ Beispiel: (Taxi-Problem)

- Die Modellannahme lautet $X_i \sim \mathcal{U}[1 : \vartheta]$ als Gleichverteilung auf der Menge $[1 : \vartheta]$ mit *unbekannter Elementanzahl*

$$\vartheta \in \mathbb{N} = \Theta$$

- Die Beobachtungen der X_i erfolgen iid.
- Damit ergibt sich¹⁴ für jeden Beobachtungsvektor die pmf:

$$p_{\vartheta}(\mathbf{x}) = \begin{cases} \left(\frac{1}{\vartheta}\right)^N, & 1 \leq x_i \leq \vartheta \text{ für alle } i \in [1 : N] \\ 0, & \text{sonst} \end{cases}$$

¹⁴ **Übung:** Überlegen Sie sich die Richtigkeit dieser Aussage.

■ Bemerkung:

- In den vergangen Beispielen wurde der gesuchte Parameter stets als $\vartheta \in \Theta$ bezeichnet, um eine konsistente Notation zu erreichen.
- In „praktischen Ingenieurs-Alltagsrechnungen“ kann selbstverständlich der Parameter p (Bernoulli), b (Temperatur) bzw. K (Taxi) verwendet werden, solange man sich der Modellierung bewusst ist.

Definition



Ein *Schätzer*, engl.: *estimator*, ist eine Abbildung¹⁵

$$T : \mathcal{X}^N \rightarrow \Theta,$$


die für jede N -fache Beobachtung einen (möglichst sinnvollen) Wert $\vartheta \in \Theta$ bestimmt.

Soll die Abhängigkeit von der Beobachtungslänge betont werden, so schreibt man $T^{(N)}$ oder T_N .

Soll die Schätzgröße hervorgehoben werden, so verwendet man auch die Schreibweise $\hat{\vartheta} : \mathcal{X}^N \rightarrow \Theta$ oder eben $\hat{\vartheta}^{(N)}$ bzw. $\hat{\vartheta}_N$.

¹⁵Hier taucht nun die Bezeichnung T auf. Natürlich kann für eine Schätzabbildung auch jede andere Bezeichnung verwendet werden, solange das aus dem Kontext klar wird.

■ **Illustration:** (einer Schätzung)



$$(\mathcal{X}^N, \mathcal{B}(\mathcal{X}^N), P_\vartheta) \longrightarrow (\Theta, \mathcal{B}(\Theta), P_T)$$

■ Diskussion:

- Der „Zufallsmechanismus steckt“ in $(\Omega, \mathcal{B}, P)$, wird durch die Zufallsvariable $X_i : \Omega \rightarrow \mathcal{X}$ auf $(\mathcal{X}, \mathcal{B}(\mathcal{X}), P_\vartheta)$ abgebildet und erzeugt dort einen „neuen“ Wahrscheinlichkeitsraum.
- Der Schätzer T ist „nur“ eine Abbildung $T : \mathcal{X}^N \rightarrow \Theta$.
- Entsprechend berechnen sich Verteilungen/Wahrscheinlichkeiten beispielsweise über

$$P_\vartheta(T \leq t) = P_\vartheta(T(\mathbf{X}) \leq t) = P_\vartheta(\{\mathbf{x} \in \mathcal{X}^N : T(\mathbf{x}) \leq t\}) \quad (\text{stetig})$$

$$P_\vartheta(T = t) = P_\vartheta(T(\mathbf{X}) = t) = P_\vartheta(\{\mathbf{x} \in \mathcal{X}^N : T(\mathbf{x}) = t\}) \quad (\text{diskret})$$

■ Bemerkungen:

- Die Beobachtung $\mathbf{X} \in \mathcal{X}^N$ ist zufällig und besitzt pmf $p_{\vartheta}(\mathbf{x})$ bzw. pdf $f_{\vartheta}(\mathbf{x})$.
- Also ist auch $T(\mathbf{X})$ bzw. $\hat{\vartheta}$ eine Zufallsvariable mit Werten in Θ und Verteilung

$$p_{\vartheta}(t) \quad \text{bzw.} \quad f_{\vartheta}(t).$$

Beachte: Ob sich für T eine diskrete oder eine stetige Verteilung ergibt, hängt von den möglichen Werten in Θ ab, nicht davon ob $\mathcal{X}$ diskret oder stetig ist!

- Demnach sind (bei Existenz) Erwartungswert und Varianz eines Schätzers:



$$\mathbb{E}_{\vartheta}(T) = \sum_{t \in \Theta} t \cdot p_{\vartheta}(t) \quad (\text{diskret})$$

$$= \int_{\mathbb{R}} t \cdot f_{\vartheta}(t) \, dt \quad (\text{stetig})$$

$$\mathbb{V}_{\vartheta}(T) = \mathbb{E}_{\vartheta} \left((T - \mathbb{E}_{\vartheta}(T))^2 \right)$$

Andere Momenten und Kenngrößen entstehen analog.

■ Beispiel:

- Für das Bernoulli-Experiment ist

$$\mathcal{X}^N = \{0, 1\}^N$$

und $t = \frac{1}{N} \sum_{i=1}^N x_i$ (relative Anzahl der Treffer) ein Schätzer:

$$T : \begin{cases} \mathcal{X}^N & \rightarrow [0, 1] \\ \mathbf{x} & \mapsto \frac{1}{N} \sum_{i=1}^N x_i \end{cases}$$

Jede Folge $\mathbf{x}$ tritt mit Wahrscheinlichkeit $p_{\vartheta}(\mathbf{x}) = \vartheta^n (1 - \vartheta)^{N-n}$ mit $n = \sum_{i=1}^N x_i$ auf, damit folgt mit $t = n/N$:

$$P\left(T = \frac{n}{N}\right) = P\left(\left\{\mathbf{x} \in \mathcal{X}^N : \sum_{i=1}^N x_i = n\right\}\right) = \binom{N}{n} \vartheta^n (1 - \vartheta)^{N-n}$$

■ Beispiel:

- Für die Temperaturmessung folgt...

Definition



Ein Schätzer $T : \mathcal{X}^N \rightarrow \Theta$ heißt *erwartungstreu*, engl.: *unbiased*, falls

$$\mathbb{E}_{\vartheta}(T) = \vartheta,$$

d.h., dass insbesondere der Erwartungswert existiert. Ein Schätzer heißt *verzerrt*, *biased*, wenn $\mathbb{E}_{\vartheta}(T) \neq \vartheta$ ist. Die *Verzerrung*, engl.: *bias*, ist:

$$b_{\vartheta}(T) = \mathbb{E}_{\vartheta}(T) - \vartheta.$$

Ein Schätzer $T : \mathcal{X}^N \rightarrow \Theta$ heißt *asymptotisch erwartungstreu*, engl.: *asymptotically unbiased*, falls

$$\lim_{N \rightarrow \infty} \mathbb{E}_{\vartheta}(T_N) = \vartheta.$$

Definition



Für einen Schätzer $T : \mathcal{X}^N \rightarrow \Theta$ ergibt sich im Fall $\mathbb{E}_{\vartheta}(T^2) < \infty$ die *mittlere quadratische Abweichung*, engl.: *mean squared error*, *MSE*:

$$\text{MSE}_{\vartheta}(T) := \mathbb{E}_{\vartheta}((T - \vartheta)^2)$$

■ Rechnung liefert:

$$\text{MSE}_{\vartheta}(T) = \mathbb{V}_{\vartheta}(T) + (b_{\vartheta}(T))^2$$

Demzufolge beinhaltet der MSE einen Kompromiss zwischen kleiner Varianz der Schätzung und kleinem Bias der Schätzung. Zudem ist ein erwartungstreuer Schätzer nicht unbedingt der beste Schätzer bzgl. des MSE.

Definition

Ein Schätzer $T : \mathcal{X}^N \rightarrow \Theta$ heißt *konsistent*, engl.: *consistent*, falls

$$\lim_{N \rightarrow \infty} P_{\vartheta} (|T_N - \vartheta| \geq \varepsilon) = 0,$$

also bei zunehmender Beobachtungslänge die Schätzung beliebig genau wird.

■ Beispiel: (Bernoulli-Experiment)

- Die Modellannahme lautet $X_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\vartheta)$, $i \in [1 : N]$ mit *unbekannter Trefferwahrscheinlichkeit*

$$\vartheta = P(X_i = 1).$$

- Damit ergibt sich für jeden Beobachtungsvektor die Wahrscheinlichkeit

$$p_{\vartheta}(\mathbf{x}) = \vartheta^n (1 - \vartheta)^{N-n}$$

mit

$$n := \sum_{i=1}^N x_i$$

■ **Beispiel:** (Bernoulli-Experiment) (ctd.)

- Definiert man damit

$$T_N(\mathbf{x}) := \frac{1}{N} \sum_{i=1}^N x_i,$$



so folgt für alle $\vartheta \in \Theta$:

$$\mathbb{E}_{\vartheta}(T_N) = \mathbb{E}_{\vartheta}(T_N(X_1, \dots, X_N)) = \mathbb{E}_{\vartheta} \left(\frac{1}{N} \sum_{i=1}^N X_i \right) = \vartheta$$

$$\mathbb{V}_{\vartheta}(T_N) = \mathbb{V}_{\vartheta}(T_N(X_1, \dots, X_N)) = \mathbb{V}_{\vartheta} \left(\frac{1}{N} \sum_{i=1}^N X_i \right) = \frac{\vartheta(1 - \vartheta)}{N}$$

- Der Schätzer ist somit erwartungstreu (und damit asymptotisch erwartungstreu) und mittels der Tschebyschev-Ungleichung auch konsistent.
- **Beachte:** Die Stichprobe $\mathbf{X}$ ist zufällig $\implies T_N(\mathbf{X})$ ist zufällig $\implies$ man kann die Verteilung von $T_N(\mathbf{X})$ simulieren, indem man viele $\mathbf{X} = \mathbf{x}$ erzeugt, jeweils $T(\mathbf{x})$ bestimmt und dessen Verteilung betrachtet

■ Beispiel:¹⁶ (Bernoulli-Experiment) (ctd.) Histogramme der Schätzergebnisse



¹⁶ Datei: estimator_Bernoulli.ipynb

■ Beispiel: (Temperaturmessung)

- Die Modellannahme lautet $X_i = \vartheta + Z_i, i \in [1 : N]$ mit *unbekannter Konstante* („Temperatur“)

$$\vartheta \in \mathbb{R}$$

- Ist beispielsweise $Z_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$, so folgt $X_i \stackrel{\text{iid}}{\sim} \mathcal{N}(\vartheta, \sigma^2)$ mit unbekanntem Erwartungswert.
- Damit ergibt sich für jeden Beobachtungsvektor die Wahrscheinlichkeitsdichte

$$f_{\vartheta}(\mathbf{x}) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \vartheta)^2}{2\sigma^2}\right).$$

■ **Beispiel:** (Temperaturmessung) (ctd.)

■ Definiert man damit

$$T_N(\mathbf{x}) := \frac{1}{N} \sum_{i=1}^N x_i,$$



so folgt für alle $\vartheta \in \Theta$:

$$\mathbb{E}_{\vartheta}(T_N) = \mathbb{E}_{\vartheta}(T_N(X_1, \dots, X_N)) = \mathbb{E}_{\vartheta} \left(\frac{1}{N} \sum_{i=1}^N X_i \right) = \vartheta$$

$$\mathbb{V}_{\vartheta}(T_N) = \mathbb{V}_{\vartheta}(T_N(X_1, \dots, X_N)) = \mathbb{V}_{\vartheta} \left(\frac{1}{N} \sum_{i=1}^N X_i \right) = \frac{\sigma^2}{N}$$

■ Der Schätzer ist somit erwartungstreu (und damit asymptotisch erwartungstreu) und mittels der Tschebyschev-Ungleichung auch konsistent.

■ Beispiel:¹⁷ (Temperaturmessung) (ctd.) Histogramme der Schätzergebnisse



¹⁷ Datei: estimator_temperature.ipynb

■ Beispiel:¹⁸ (Übung) (Taxi-Problem)



- Überlegen und argumentieren Sie, ob im Taxi-Problem $\mathcal{X}^N = [1 : \vartheta]^N$ sowie $\Theta = \mathbb{N}$ der folgende Schätzer erwartungstreu für ϑ ist:

$$T_N(\mathbf{x}) := \max_{1 \leq i \leq N} x_i$$

- Falls Sie zu dem Schluss kommen, dass der Schätzer nicht erwartungstreu ist...: Wie könnte ein erwartungstreuer Schätzer aussehen?
- **Hinweis:** Obige Übung ist als anschauliche Begründung gedacht. Falls Sie eine ähnliche Aussage *rechnen* wollen, verwenden Sie als Modell die kontinuierliche Gleichverteilung mit $X_i \sim \mathcal{U}(0, \vartheta)$ und somit $\mathcal{X}^N = (0, \vartheta)^N$. Beachten Sie dann

$$\{\max\{X_1, \dots, X_N\} \leq v\} = \{X_1 \leq v, \dots, X_N \leq v\}.$$

¹⁸ **Datei:** estimator_taxi.ipynb

■ Idee:

- Gegeben ist ein statistisches Modell $(\mathcal{X}, (P_{\vartheta})_{\vartheta \in \Theta})$.
- Wird nun eine bestimmte Beobachtung $\mathbf{X} = \mathbf{x}$ beobachtet, so [Hen17]:

„[...] hilft oft eine von R.A. Fischer eingeführte allgemein und intuitiv naheliegende Konstruktionsmethode [...] denjenigen Parameterwert ϑ für den „glaubwürdigsten“ zu halten, welcher dem beobachteten Ereignis $\{\mathbf{X} = \mathbf{x}\}$ die größte Wahrscheinlichkeit des Eintretens verleiht.“

Definition




In dem statistischen Modell $(\mathcal{X}, (P_{\vartheta})_{\vartheta \in \Theta})$ lautet die *Likelihood-Funktion*¹⁹, engl.: *likelihood function*:

$$L_{\mathbf{x}}(\vartheta) := p_{\vartheta}(\mathbf{x}) \quad \text{bzw.} \quad L_{\mathbf{x}}(\vartheta) := f_{\vartheta}(\mathbf{x})$$

Diese Funktion $L_{\mathbf{x}}(\vartheta)$ bewertet, wie wahrscheinlich die Beobachtung $\mathbf{X} = \mathbf{x}$ unter der Modellannahme P_{ϑ} bei Gültigkeit eines $\vartheta \in \Theta$ ist.

¹⁹auch: Plausibilitätsfunktion

■ **Beispiel:**²⁰ Likelihood-Funktion $L_{\mathbf{x}}(\vartheta) = p_{\vartheta}(\mathbf{x})$ für das Bernoulli-Experiment für $N = 100$



²⁰ Datei: likelihood_function.ipynb

Definition



In dem statistischen Modell $(\mathcal{X}, (P_{\vartheta})_{\vartheta \in \Theta})$ ist $\hat{\vartheta}_{\text{ML}}$ ein *Maximum-Likelihood-Schätzer*, *ML-Schätzer*, engl.: *maximum likelihood estimator*, *ML estimator*, falls

$$L_{\mathbf{x}}(\hat{\vartheta}_{\text{ML}}) = \sup_{\vartheta \in \Theta} L_{\mathbf{x}}(\vartheta).$$

■ Aus [Hen95]:

„[...] In den meisten statistischen Anwendungen existiert ein eindeutig bestimmter ML-Schätzer $\hat{\vartheta}$, und er ist gewöhnlich ein „guter“ Schätzer für ϑ .“

■ Bemerkung:

- Ist $\Theta \subseteq \mathbb{R}$ kompakt und sind alle Funktionen stetig, so entsteht beim ML-Schätzer ein Maximum statt eines Supremums.
- Ist $\Theta \subseteq \mathbb{R}$ und sind alle Funktionen differenzierbar, so kann der ML-Schätzer oft durch Ableiten und Nullsetzen gefunden werden (siehe nächstes Beispiel). Hierbei ist zu beachten, dass die Maximumeigenschaft überprüft werden muss (z.B. 2. Ableitung) und auf Randpunkt geachtet werden muss. 
- Oft verwendet man – insbesondere falls wie oben erwähnt die Ableitung verwendet werden soll – statt der Likelihood-Funktion die *Log-Likelihood-Funktion*

$$\ln(L_{\mathbf{x}}(\vartheta)).$$

Zudem geht dann die Multiplikation von pmf/pdf bei unabhängigen Beobachtungen in die Addition von Log-Likelihood-Werten über, wodurch oft die Rechnung vereinfacht wird.

■ Beispiele:

- Für das Bernoulli-Experiment ergibt sich für jeden Beobachtungsvektor die Wahrscheinlichkeit

$$p_{\vartheta}(\mathbf{x}) = \vartheta^n (1 - \vartheta)^{N-n}, \quad n := \sum_{i=1}^N x_i$$

- Für die Temperaturmessung ist

$$f_{\vartheta}(\mathbf{x}) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \vartheta)^2}{2\sigma^2}\right).$$

- Beim *Taxi-Problem* ist $\mathcal{X}^N = [1 : \vartheta]^N$ sowie $\Theta = \mathbb{N}$ und

$$p_{\vartheta}(\mathbf{x}) = \begin{cases} \left(\frac{1}{\vartheta}\right)^N, & 1 \leq x_i \leq \vartheta \text{ für alle } i \in [1 : N] \\ 0, & \text{sonst} \end{cases}$$

Definition²¹

In dem statistischen Modell $(\mathcal{X}, (P_{\vartheta})_{\vartheta \in \Theta})$ ist der *Score*, engl.: *score*²², einer Zufallsvariablen $\mathbf{X}$ definiert durch

$$S := \frac{\partial}{\partial \vartheta} \ln (L_{\mathbf{X}}(\vartheta))$$

also:

$$S := \frac{\partial}{\partial \vartheta} \ln (p_{\vartheta}(\mathbf{X})) \quad (\text{diskreter Fall})$$

$$S := \frac{\partial}{\partial \vartheta} \ln (f_{\vartheta}(\mathbf{X})) \quad (\text{stetiger Fall})$$

²¹Nach [CT06]

²²Übersetzung ist hier etwas unnötig, da direkt die englische Bezeichnung verwendet wird. ;-)

Annahme^{23 24}

Für die folgenden Betrachtungen nehmen wir an, dass folgende Umformungen zulässig sind:²⁵

$$\int_{-\infty}^{\infty} \frac{\partial}{\partial \vartheta} f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} = \frac{\partial}{\partial \vartheta} \int_{-\infty}^{\infty} f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} \quad (\text{U1})$$

$$\int_{-\infty}^{\infty} \frac{\partial}{\partial \vartheta} f_{\vartheta}(\mathbf{x}) \cdot T(\mathbf{x}) \, d\mathbf{x} = \frac{\partial}{\partial \vartheta} \int_{-\infty}^{\infty} f_{\vartheta}(\mathbf{x}) \cdot T(\mathbf{x}) \, d\mathbf{x} \quad (\text{U2})$$

Für diskrete Verteilungen ergeben sich äquivalente Anforderungen, in denen die Vertauschbarkeit von Summation und Ableitung gefordert wird.

²³Nach [Pap91]

²⁴Es wird später anhand eines Beispiels gezeigt werden, dass diese erforderlich sind.

²⁵Alle Integrale sind so zu verstehen, dass die Funktionen in den Integrationsbereichen wohldefiniert sind!

Satz/Definition

In dem statistischen Modell $(\mathcal{X}, (P_{\vartheta})_{\vartheta \in \Theta})$ gilt für den Score:

$$\mathbb{E}_{\vartheta}(S) = 0.$$

Die *Fisher-Information*, engl.: *Fisher information*, ist definiert als Varianz des Scores:

$$\begin{aligned} J(\vartheta) &:= \mathbb{V}_{\vartheta}(S) \\ &= \mathbb{E}_{\vartheta} \left(\left(\frac{\partial}{\partial \vartheta} \ln(p_{\vartheta}(\mathbf{X})) \right)^2 \right) \quad (\text{diskreter Fall}) \\ &= \mathbb{E}_{\vartheta} \left(\left(\frac{\partial}{\partial \vartheta} \ln(f_{\vartheta}(\mathbf{X})) \right)^2 \right) \quad (\text{stetiger Fall}) \end{aligned}$$

■ Nachweis:

■ Man rechnet: ²⁶ ²⁷

$$\begin{aligned}\mathbb{E}_{\vartheta}(S) &= \int_{-\infty}^{\infty} \frac{\partial}{\partial \vartheta} \ln(f_{\vartheta}(\mathbf{x})) \cdot f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} \\ &= \int_{-\infty}^{\infty} \frac{\frac{\partial}{\partial \vartheta} f_{\vartheta}(\mathbf{x})}{f_{\vartheta}(\mathbf{x})} \cdot f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} \\ &= \int_{-\infty}^{\infty} \frac{\partial}{\partial \vartheta} f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} \\ &\stackrel{(U1)}{=} \frac{\partial}{\partial \vartheta} \int_{-\infty}^{\infty} f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} \\ &= 0\end{aligned}$$

²⁶ Hier für stetige ϑ nachgerechnet. Der Nachweis des diskreten Falls erfolgt analog.

²⁷ Der Definitionsbereich der Integrale wird so gewählt, dass alle Berechnung zulässig sind. Ebenso wird angenommen, dass die Vertauschung von Ableitung und Integration zulässig ist.

Satz (Cramér-Rao-Ungleichung)

In dem statistischen Modell $(\mathcal{X}, (P_{\vartheta})_{\vartheta \in \Theta})$ gilt für jeden Schätzer $T : \mathcal{X}^N \rightarrow \Theta$:

$$\mathbb{V}_{\vartheta}(T) = \mathbb{E} \left((T - \mathbb{E}_{\vartheta}(T))^2 \right) \geq \frac{\left(\frac{\partial}{\partial \vartheta} \mathbb{E}_{\vartheta}(T) \right)^2}{J(\vartheta)}$$

Ist der Schätzer T erwartungstreu, so lautet die Ungleichung:

$$\mathbb{V}_{\vartheta}(T) = \mathbb{E}_{\vartheta}((T - \vartheta)^2) \geq \frac{1}{J(\vartheta)}$$

■ Nachweis:

■ Ansatz (im stetigen Fall): Aufgrund der Cauchy-Schwarz-Ungleichung (siehe Kap. 8 oder [PJ19]) gilt

$$(\text{Cov}(S, T))^2 \leq \mathbb{V}_{\vartheta}(S) \cdot \mathbb{V}_{\vartheta}(T) = J(\vartheta) \cdot \mathbb{V}_{\vartheta}(T),$$

es ist aber auch (beachte $E_{\vartheta}(S) = 0$)

$$\begin{aligned} \text{Cov}(S, T) &= \mathbb{E}_{\vartheta}(S \cdot T) \\ &= \int_{-\infty}^{\infty} \frac{\partial}{\partial \vartheta} \ln(f_{\vartheta}(\mathbf{x})) \cdot T(\mathbf{x}) \cdot f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} \\ &= \int_{-\infty}^{\infty} \frac{\frac{\partial}{\partial \vartheta} f_{\vartheta}(\mathbf{x})}{f_{\vartheta}(\mathbf{x})} \cdot T(\mathbf{x}) \cdot f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} \\ &\stackrel{(\text{U2})}{=} \frac{\partial}{\partial \vartheta} \int_{-\infty}^{\infty} f_{\vartheta}(\mathbf{x}) \cdot T(\mathbf{x}) \, d\mathbf{x} \\ &= \frac{\partial}{\partial \vartheta} E_{\vartheta}(T) \end{aligned}$$

Definition

In dem statistischen Modell $(\mathcal{X}, (P_{\vartheta})_{\vartheta \in \Theta})$ heißt ein erwartungstreuer Schätzer $T : \mathcal{X}^N \rightarrow \Theta$ *effizient*, engl.: *efficient*, falls

$$\mathbb{V}_{\vartheta}(T) = \frac{1}{J(\vartheta)},$$

d.h. falls er in der Cramér-Rao-Ungleichung die untere Schranke annimmt.

■ Bemerkung:

■ Für die Fisher-Information kann oft die folgende Betrachtung (hier für den stetigen Fall) hilfreich sein:

$$\begin{aligned} 0 &= \frac{\partial^2}{\partial \vartheta^2} \int_{-\infty}^{\infty} f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} = \frac{\partial}{\partial \vartheta} \int_{-\infty}^{\infty} \frac{\partial}{\partial \vartheta} f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} \\ &= \frac{\partial}{\partial \vartheta} \int_{-\infty}^{\infty} \frac{\partial}{\partial \vartheta} [\ln(f_{\vartheta}(\mathbf{x}))] \cdot f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} \\ &= \int_{-\infty}^{\infty} \frac{\partial^2}{\partial \vartheta^2} [\ln(f_{\vartheta}(\mathbf{x}))] \cdot f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} + \int_{-\infty}^{\infty} \frac{\partial}{\partial \vartheta} [\ln(f_{\vartheta}(\mathbf{x}))] \cdot \frac{\partial}{\partial \vartheta} [f_{\vartheta}(\mathbf{x})] \, d\mathbf{x} \\ &= \int_{-\infty}^{\infty} \frac{\partial^2}{\partial \vartheta^2} [\ln(f_{\vartheta}(\mathbf{x}))] \cdot f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} + \int_{-\infty}^{\infty} \left(\frac{\partial}{\partial \vartheta} \ln(f_{\vartheta}(\mathbf{x})) \right)^2 \cdot f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} \end{aligned}$$

■ **Bemerkung:** (ctd.)

■ Weiter rechnen:

$$\begin{aligned} 0 &= \int_{-\infty}^{\infty} \frac{\partial^2}{\partial \vartheta^2} [\ln(f_{\vartheta}(\mathbf{x}))] \cdot f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} + \int_{-\infty}^{\infty} \left(\frac{\partial}{\partial \vartheta} \ln(f_{\vartheta}(\mathbf{x})) \right)^2 \cdot f_{\vartheta}(\mathbf{x}) \, d\mathbf{x} \\ &= \mathbb{E}_{\vartheta} \left(\frac{\partial^2}{\partial \vartheta^2} \ln(f_{\vartheta}(\mathbf{x})) \right) + \mathbb{E}_{\vartheta} \left(\left(\frac{\partial}{\partial \vartheta} \ln(f_{\vartheta}(\mathbf{x})) \right)^2 \right) \end{aligned}$$

■ Zusammengefasst:

$$J(\vartheta) = \mathbb{E}_{\vartheta} \left(\left(\frac{\partial}{\partial \vartheta} \ln(f_{\vartheta}(\mathbf{x})) \right)^2 \right) = -\mathbb{E}_{\vartheta} \left(\frac{\partial^2}{\partial \vartheta^2} \ln(f_{\vartheta}(\mathbf{x})) \right)$$

Die zweite Berechnung ist oft einfacher, beispielsweise wenn in iid-Stichproben $\ln(f_{\vartheta}(\mathbf{x}))$ zu einer Summe wird!



■ **Beispiel:** (Temperaturmessung)

- Das Modell besteht in

$$f_{\vartheta}(\mathbf{x}) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \vartheta)^2}{2\sigma^2}\right).$$

und hat den ML-Schätzer geliefert:

$$T(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N x_i,$$

- Ist dieser effizient?

■ Beispiel/Bemerkung: (nach [Pap91])

- Die Gültigkeit der beiden vorausgesetzten Umformungen ist essenziell, denn ...
- Betrachte das Modell einer Gleichverteilung mit unbekannter Intervalllänge:

$$(\mathcal{X}, (P_{\vartheta})_{\vartheta \in \Theta}) = (\mathbb{R}_{>0}, (\mathcal{U}(0, \vartheta))_{\vartheta \in \mathbb{R}_{>0}})$$

- Bei N unabhängigen Beobachtungen folgt:

$$F_{\vartheta}(\mathbf{x}) = \left(\frac{1}{\vartheta}\right)^N \mathbb{1}\{0 < x_1, \dots, x_N < \vartheta\}$$

- Damit ergibt sich der ML-Schätzer:

$$T(x_1, \dots, x_N) = \max\{x_1, \dots, x_N\}$$

mit: ([Pap91] oder **Übung**)

$$E_{\vartheta}(T(X_1, \dots, X_N)) = \frac{N}{N+1} \vartheta$$

$$V_{\vartheta}(T(X_1, \dots, X_N)) = \vartheta^2 \frac{N}{(N+1)^2(N+2)}$$

■ **Beispiel/Bemerkung:** (nach [Pap91]) (ctd.)

- Für die rechte Seite der Cramér-Rao-Ungleichung rechnet man

$$\begin{aligned}\frac{\partial}{\partial \vartheta} E_{\vartheta}(T) &= \frac{N}{N+1} \\ E_{\vartheta} \left(\left[\frac{\partial}{\partial \vartheta} \ln(f_{\vartheta}(\mathbf{x})) \right]^2 \right) &= \frac{N^2}{\vartheta^2}\end{aligned}$$

und somit:

$$\frac{\left(\frac{\partial}{\partial \vartheta} \mathbb{E}_{\vartheta}(T) \right)^2}{J(\vartheta)} = \frac{N^2}{(N+1)^2} \cdot \frac{\vartheta^2}{N^2} = \frac{\vartheta^2}{(N+1)^2} > \vartheta^2 \frac{N}{(N+1)^2(N+2)} = V_{\vartheta}(T)$$

- **Übung:**²⁸ Welche Umformung im Nachweis der Cramér-Rao-Schranke ist nicht korrekt und wieso?

²⁸Bei Interesse!

- Neben dem ML-Ansatz zur Bestimmung eines Schätzwertes ist in ETIT/MEDT-Fragestellungen auch der MMSE-Ansatz gebräuchlich
- Hierzu wird, ausgehend von entsprechenden Signal- und Schätzmodellen, der *mittlere quadratische Fehler (MSE)* minimiert, engl. *minimum mean-squared error, MMSE*
- Die Definition und Rechnungen werden an unserem Temperaturbeispiel illustriert...²⁹

²⁹Das erfordert etwas Vektor-Matrix-Rechnung, deren Übung aber für später gar nicht schlecht ist.

Definition

Der *kleinste Quadrate-Schätzer*, engl. *minimum mean squared estimator*, *MMSE*,³⁰ minimiert die erwartete quadratische Abweichung:

$$\hat{T}_{\text{MMSE}} := \arg \min \mathbb{E} \left(|T(\mathbf{X}) - \vartheta|^2 \right)$$

³⁰Beachte: Für nicht-erwartungstreue Schätzer entspricht der MSE nicht der Varianz; siehe vorherige Betrachtungen.

■ **Beispiel:** (Temperaturmessung)

- Die Modellannahme lautet

$$X_i = b + Z_i, \quad Z_i \stackrel{\text{iid}}{\sim} f_Z(z), \quad i \in [1 : N]$$

mit *unbekanntem Parameter* $b \in \mathbb{R}$ und unabhängigen Rauschgrößen $Z_1, \dots, Z_N$ mit $\mathbb{E}(Z_i) = 0$

- Dies kann als Vektorgleichung geschrieben werden:

$$\mathbf{X} = b \underbrace{\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}}_{=: \mathbf{1}_{N \times 1}} + \mathbf{Z},$$

mit der Rauschkorrelationsmatrix

$$\mathbf{R}_{\mathbf{Z}\mathbf{Z}} = \mathbb{E}(\mathbf{Z}\mathbf{Z}^T) = \sigma_Z^2 \mathbf{I}$$

■ Beispiel: (Temperaturmessung) (ctd.)

■ Aus dem Modell

$$\mathbf{X} = b\mathbf{1}_{N \times 1} + \mathbf{Z}$$

folgt:

$$\begin{aligned}\mathbf{R}_{\mathbf{X}\mathbf{X}} &= \mathbb{E}(\mathbf{X}\mathbf{X}^T) = \mathbb{E}((b\mathbf{1}_{N \times 1} + \mathbf{Z})(b\mathbf{1}_{N \times 1} + \mathbf{Z})^T) \\ &\stackrel{(a)}{=} b^2\mathbf{1}_{N \times N} + \mathbf{R}_{\mathbf{Z}\mathbf{Z}} = b^2\mathbf{1}_{N \times N} + \sigma_Z^2\mathbf{I},\end{aligned}$$

wobei (a) gilt, da b nicht zufällig ist und $\mathbb{E}(Z_i) = 0$ angenommen wurde.

■ Beispiel: (Temperaturmessung) (ctd.)

- Nach dem Orthogonalitätsprinzip^{31 32} wird der quadratische Fehler minimal, wenn der Fehler orthogonal zu dem Unterraum ist, in dem die Approximation erfolgt.
- Wird eine lineare Schätzung mit Gewichten $(g_1, \dots, g_N)$ angenommen, so ist

$$\hat{b} = \sum_{n=1}^N g_n x_n$$

und der Schätzwert wird aus den x_i aufgebaut.

- Dies liefert für alle $j \in [1 : N]$:

$$\mathbb{E} \left(\left(\hat{b} - b \right) X_j \right) \stackrel{!}{=} 0 \quad \Leftrightarrow \quad \mathbb{E} \left(\left(\sum_{n=1}^N g_n X_n \right) X_j \right) \stackrel{!}{=} \mathbb{E} (b X_j)$$

³¹alternativ: Gaußapproximation, Bestapproximation, ..., siehe „Signale und Systeme“

³²Falls Sie diesem Ansatz nicht vertrauen: Ableiten und Nullsetzen führt auf identische Gleichung (**Übung**). In späteren Problemstellungen in höheren Dimensionen ist der Weg über die Ableitung oft nicht oder nur schwer gangbar, sodass dort das Orthogonalitätsprinzip eine brauchbare Alternative bietet.

■ **Beispiel:** (Temperaturmessung) (ctd.)

■ **Erinnerung:** Für alle $j \in [1 : N]$ muss gelten:

$$\mathbb{E} \left(\left(\sum_{n=1}^N g_n X_n \right) X_j \right) \stackrel{!}{=} \mathbb{E} (b X_j)$$

■ Die Beziehung kann mit $\mathbf{g}^T = (g_1, \dots, g_N)$ umgeschrieben werden zu:

$$\mathbf{R}_{XX} \mathbf{g} = b^2 \mathbf{1}_{N \times 1}$$

■ Einsetzen ergibt:

$$\mathbf{g} = (b^2 \mathbf{1}_{N \times N} + \sigma_Z^2 \mathbf{I})^{-1} b^2 \mathbf{1}_{N \times 1} = \left(\mathbf{1}_{N \times N} + \frac{\sigma_Z^2}{b^2} \mathbf{I} \right)^{-1} \mathbf{1}_{N \times 1}$$

■ **Beispiel:** (Temperaturmessung) (ctd.)

■ **Erinnerung:** Die MMSE-Schätzung verwendet:

$$\mathbf{g} = \left(\mathbf{1}_{N \times N} + \frac{\sigma_Z^2}{b^2} \mathbf{I} \right)^{-1} \mathbf{1}_{N \times 1} = (\mathbf{I} + \text{SNR} \cdot \mathbf{1}_{N \times N})^{-1} \text{SNR} \cdot \mathbf{1}_{N \times 1}$$

mit der Definition $\text{SNR} = b^2 / \sigma_Z^2$

■ Über die Sherman-Morrison-Woodbury-Formel³³ ergibt sich:


$$\mathbf{g} = \frac{1}{N + \frac{1}{\text{SNR}}} \mathbf{1}_{N \times 1}$$

und damit

$$\hat{b}_{\text{MMSE}} = \frac{1}{N + \frac{1}{\text{SNR}}} \sum_{n=1}^N x_n$$

³³Siehe beispielsweise <https://de.wikipedia.org/wiki/Sherman-Morrison-Woodbury-Formel>

■ Beispiel:³⁴ ³⁵ (Temperaturmessung) (ctd.)




³⁴ Datei: example_temperature.ipynb

³⁵ Zur Erinnerung: Das SNR war definiert als $\text{SNR} = b^2 / \sigma_Z^2$ und beschreibt das Verhältnis von Signalleistung zu Rauschleistung

■ Beispiel: (Ausblick: Phasenschätzung)

- MMSE-Schätzung einer unbekannten Phase in einem Kommunikationssystem³⁶
- Zum Vergleich: Approximation der Cramér-Rao-Schranke („modified Cramér-Rao bound, MCRB“)



³⁶... natürlich ist klar, dass Ihnen die aufgeführten E_s/N_0 -Werte nicht sagen; hier muss ich Sie bis zu Modulen zum Thema Nachrichtentechnik vertrösten...

- **Bisher:** Schätzung eines unbekannten Parameters in dem Modell $(\mathcal{X}, (P_\vartheta)_{\vartheta \in \Theta})$
- **Aber:** Keine Aussage über Wahrscheinlichkeit einer korrekten Schätzung

■ **Idee:** Angabe einer „Erfolgswahrscheinlichkeit“ der Schätzung

■ **Beispiel:**³⁷

- Betrachte eine Bernoulliverteilung $\text{Bernoulli}(p)$ mit unbekannter Wahrscheinlichkeit p und eine iid Beobachtung $(X_1, \dots, X_N)$
- Dann gilt für den Mittelwertschätzer $\hat{p} = \frac{1}{N} \sum_{i=1}^N x_i$ mit der Tschebyschev-Ungleichung:

$$P(|\hat{p} - p| \geq \delta) \leq \frac{\mathbb{V}\left(\frac{1}{N} \sum_{i=1}^N X_i\right)}{\delta^2} = \frac{\mathbb{V}(X_1)}{N\delta^2} = \frac{p(1-p)}{N\delta^2} \leq \frac{1}{4N\delta^2}$$

■ Wählt man³⁸ $N \geq 1/(4\delta^2 \cdot 0,05)$, dann ist

$$P(\hat{p} - \delta < p < \hat{p} + \delta) = 1 - P(|\hat{p} - p| \geq \delta) \geq 0,95$$

³⁷Nach [Kre91]

³⁸So lautet beispielsweise für $\delta = 0,01$ die Bedingung $N \geq 1/(4 \cdot (10^{-2})^2 \cdot 5 \cdot 10^{-2}) = 1/(20 \cdot 10^{-6}) = 50.000$

Definition³⁹

Für ein statistisches Modell $(\mathcal{X}, (P_{\vartheta})_{\vartheta \in \Theta})$ sei

$$\{C(\mathbf{x}) : \mathbf{x} \in \mathcal{X}^N\} \subseteq \mathcal{P}(\Theta).$$

Dann heißt $C(\mathbf{x})$ *Konfidenzbereich zum Niveau $1 - \alpha$* , falls

$$P_{\vartheta}(\{\mathbf{x} \in \mathcal{X}^N : \vartheta \in C(\mathbf{x})\}) \geq 1 - \alpha$$

Sind Θ und $C(\mathbf{x})$ Intervalle, so heißt $C(\mathbf{x})$ *Konfidenzintervall zum Niveau $1 - \alpha$* .

³⁹Nach [Kre91]

■ Bemerkungen:

- Natürlich sollten die Konfidenzintervalle für ein gegebenes Niveau so klein wie möglich sein, damit der tatsächliche Wert möglichst gut eingegrenzt wird.
- Einfaches (und nutzloses) Beispiel: $C(\mathbf{x}) = \Theta$ ist ein Konfidenzintervall zum Niveau 1.
- Ein Konfidenzbereich kann als Abbildung betrachtet werden:

$$C : \mathcal{X}^N \rightarrow \mathcal{P}(\Theta)$$

und ordnet jeder einfachen Beobachtung ein Intervall zu, welches mit Niveau $1 - \alpha$ den wahren Parameter ϑ enthält.

- Zur Berechnung von Konfidenzintervallen kann man Vorschriften

$$G_u : \mathcal{X}^N \rightarrow \mathbb{R}$$

$$G_o : \mathcal{X}^N \rightarrow \mathbb{R}$$

angeben und damit das Konfidenzintervall $[G_u(\mathbf{X}), G_o(\mathbf{X})]$ bilden. [Bo94]

■ Beachte:⁴⁰

„[...] Nicht ϑ ist zufällig, sondern x und damit $C(x)$. Wird also ein Konfidenzintervall [...] angegeben, so ist nicht etwa die Wahrscheinlichkeit $\geq 0,95$, dass es ϑ enthält. Für ein festes Intervall I gilt entweder $\vartheta \in I$ oder nicht, aber $\{\vartheta \in [0, 1] : \vartheta \in I\}$ ist kein „Ereignis“, dem wir eine Wahrscheinlichkeit zugeordnet haben. [...]

Wenn wir für jedes x das Intervall $C(x)$ als Konfidenzintervall angeben [...] wird das zufällige Intervall $C(x)$ in ca. 95 % der Fälle ϑ enthalten. [...]


■ Besser wäre somit die Schreibweise:

$$P_{\vartheta} \left(\{x \in \mathcal{X}^N : C(x) \ni \vartheta\} \right) \geq 1 - \alpha$$

„Die Wahrscheinlichkeit derjenigen x , deren Konfidenzintervall ϑ überdeckt, ist mindestens $1 - \alpha$.“

⁴⁰Aus [Kre91]

- **Beispiel:**⁴¹ Bestimmung von 100 Konfidenzintervallen einer Bernoulli(p)-Verteilung mit zu schätzendem Parameter $p = 0,6$ bei Beobachtungslänge $N = 100$ bei Verwendung der „Tschebyschev-Idee“ $I = [\hat{p} - \delta, \hat{p} + \delta]$ von Folie 74



⁴¹ **Datei:** confidence_interval.ipynb

- Nun wird eine alternative Bestimmung (ohne Tschebyschev) eines Konfidenzintervalls anhand eines Beispiels aus [Bo94] demonstriert.
- Als Modell werden N Beobachtungen einer Bernoulli(p)-Verteilung mit unbekanntem p betrachtet
- Somit ist hier also $\vartheta = p$ und $\Theta = [0, 1]$
- In diesem Fall ist $T(x_1, \dots, x_N) = \bar{x}_N = \frac{1}{N} \sum_{i=1}^N x_i$ ein guter Punktschätzer (der ML-Schätzer) und es gilt nach Folie 40:

$$\mathbb{E}(\bar{X}_N) = p$$

$$\mathbb{V}(\bar{X}_N) = \frac{1}{N}p(1 - p)$$

- Aufgrund des ZGWS ist für jedes $c \in \mathbb{R}$:

$$P \left(-c \leq \frac{\bar{X}_N - p}{\sqrt{\frac{1}{N}p(1-p)}} \leq c \right) \approx \Phi(c) - \Phi(-c) = 2\Phi(c) - 1$$

- Nun berechnet man c so, dass $2\Phi(c) - 1 = 1 - \alpha$ gilt:

$$2\Phi(c) - 1 \stackrel{!}{=} 1 - \alpha \implies c \stackrel{!}{=} z_{1-\frac{\alpha}{2}} := \Phi^{-1} \left(1 - \frac{\alpha}{2} \right)$$

Das entspricht dem $(1 - \frac{\alpha}{2})$ -Quantil der Standardnormalverteilung, also dem Wert oberhalb dessen die Wahrscheinlichkeit $\frac{\alpha}{2}$ liegt.

- Damit ist die in P stehende Ungleichung mit Wahrscheinlichkeit $1 - \alpha$ erfüllt:

$$P \left(-z_{1-\frac{\alpha}{2}} \leq \frac{\bar{X}_N - p}{\sqrt{\frac{1}{N}p(1-p)}} \leq z_{1-\frac{\alpha}{2}} \right) \approx 1 - \alpha$$

- Rechnung liefert mit $S_N = N\bar{X}_N$:

$$-z_{1-\frac{\alpha}{2}} \leq \frac{\bar{X}_N - p}{\sqrt{\frac{1}{N}p(1-p)}} \leq z_{1-\frac{\alpha}{2}} \iff (S_N - Np)^2 \leq z_{1-\frac{\alpha}{2}}^2 Np(1-p)$$

$$\iff p^2(z_{1-\frac{\alpha}{2}}^2 + N) - p(2S_N + z_{1-\frac{\alpha}{2}}^2) + \frac{1}{N}S_N^2 \leq 0$$

- Bestimmung der Nullstellen bzgl. p ergibt (Details siehe [Bo94]) die Grenzen:


$$G_u = \frac{1}{N + z_{1-\frac{\alpha}{2}}^2} \left(S_N + \frac{z_{1-\frac{\alpha}{2}}^2}{2} - z_{1-\frac{\alpha}{2}} \sqrt{\frac{S_N(N - S_N)}{N} + \frac{z_{1-\frac{\alpha}{2}}^2}{4}} \right)$$

$$G_o = \frac{1}{N + z_{1-\frac{\alpha}{2}}^2} \left(S_N + \frac{z_{1-\frac{\alpha}{2}}^2}{2} + z_{1-\frac{\alpha}{2}} \sqrt{\frac{S_N(N - S_N)}{N} + \frac{z_{1-\frac{\alpha}{2}}^2}{4}} \right)$$

- (Natürlich muss man die Formeln nicht auswendig kennen! Es geht darum, die Idee dahinter zu verstehen.)

- Somit kann man für jede Beobachtung die Werte G_u und G_o berechnen
- Die daraus gebildeten Intervalle $[G_u, G_o]$ werden in $100\% \cdot (1 - \alpha)$ aller Realisierungen $\mathbf{X} = \mathbf{x}$ den wahren Parameter p enthalten
- **Bemerkungen:**
 - Die Länge der Konfidenzintervalle sinkt mit wachsendem N
 - Die Länge der Konfidenzintervalle steigt mit kleinerem α

- **Beispiel:**⁴² Bestimmung von 100 Konfidenzintervallen einer Bernoulli(p)-Verteilung mit zu schätzendem Parameter $p = 0,6$ bei Beobachtungslänge $N = 100$ bei Verwendung der „ZGWS-Idee“



⁴² Datei: confidence_interval.ipynb

■ Beispiel: ([Bo94])

- Unter 87 827 Geburten in Niedersachsen im Jahr 1972 waren 45 195 Jungen.
- Die Konfidenzintervalle für die Wahrscheinlichkeit, dass ein neugeborenes Kind ein Junge ist, ergeben sich für die jeweiligen Konfidenzniveaus die folgenden Konfidenzintervalle:

$$1 - \alpha = 0,99 \implies [g_u, g_o] = [0,5102, 0,5189]$$

$$1 - \alpha = 0,999 \implies [g_u, g_o] = [0,5094, 0,5201]$$

■ **Beispiel:** (Wahlprognose/Umfragen) ([Kre91])

- Gegeben ist eine Gesamtheit von K Personen.
- Es soll der Prozentsatz der Wähler einer Partei geschätzt werden; definiert man das Ereignis $E := \{\text{Person wählt Partei}\}$, so ist also

$$p := P(E).$$

- Werden N Personen gefragt, ob sie die Partei wählen, so ist (siehe unser Bernoulli-Beispiel)

$$p \approx \frac{1}{N} \sum_{n=1}^N \mathbb{1}_E\{\text{Person } n\}$$

ein guter Schätzer für p .

- Soweit nichts Neues, das kennen wir schon. Nun wollen wir aber nicht den Schätzer finden, sondern herleiten, wie groß die Stichprobe sein muss...

■ **Beispiel:** (Wahlprognose/Umfragen) ([Kre91]) (ctd.)

- Ziel ist es, die Wahlwahrscheinlichkeit p bis auf Δ_p so genau zu schätzen, dass die Fehlerwahrscheinlichkeit nicht größer als p_{Fehler} ist.
- Der Ansatz lautet wie für die ZGWS-Approximation eines Konfidenzintervalls. Mit der Definition $X_n := \mathbb{1}_E\{\text{Person } n\}$ folgt:

$$\begin{aligned} 1 - p_{\text{Fehler}} &\stackrel{!}{\approx} P(-\Delta_p \leq \bar{X}_N - p \leq \Delta_p) \\ &\stackrel{(a)}{\approx} P\left(-\frac{N\Delta_p}{\sqrt{Np(1-p)}} \leq \frac{S_N - Np}{\sqrt{Np(1-p)}} \leq \frac{N\Delta_p}{\sqrt{Np(1-p)}}\right) \\ &\stackrel{(a)}{\approx} 2\Phi\left(\frac{N\Delta_p}{\sqrt{Np(1-p)}}\right) - 1, \end{aligned}$$

wobei (a) eine Standardisierung und (b) der ZGWS ist.

■ **Beispiel:** (Wahlprognose/Umfragen) ([Kre91]) (ctd.)

■ **Erinnerung:**

$$1 - p_{\text{Fehler}} \approx 2\Phi\left(\frac{N\Delta_p}{\sqrt{Np(1-p)}}\right) - 1 \iff N \approx \left[\frac{1}{\Delta_p}\Phi^{-1}\left(1 - \frac{p_{\text{Fehler}}}{2}\right)\right]^2 \cdot p(1-p)$$


■ Δ_p und p_{Fehler} gegeben $\implies$ löse Gleichung auf und erhalte Werte für N ...^{43 44}

$N \geq \cdot$	$\Delta_p = 0,1$	$\Delta_p = 0,05$	$\Delta_p = 0,01$
$p_{\text{Fehler}} = 0,1$	67,64	96,04	165,87
$p_{\text{Fehler}} = 0,05$	270,55	384,15	663,49
$p_{\text{Fehler}} = 0,01$	6763,86	9603,65	16 587,24

⁴³Beachten Sie: Wie schon in Kap. 8 kennen wir den Wert $p(1-p)$ nicht, sondern wollen ihn ja erst bestimmen. Wie dort schätzen wir $p(1-p) \leq \frac{1}{4}$ ab. Damit sind die berechneten Werte für N überschätzt. Gerade für kleine Werte von p ist die Abschätzung sehr grob.

⁴⁴**Frage/Übung:** Welche Eigenschaften bemerken Sie bei der Berechnung von N ?

- **Beispiel:** (Wahlprognose/Umfragen) ([Kre91]) (ctd.)
 - Grafische Darstellung der benötigten Umfragegrößen



Ausgangspunkt

Gegeben ist (wieder mal) eine iid Beobachtung bzw. einfache Stichprobe

$$\mathbf{X} = (X_1, \dots, X_N) = (x_1, \dots, x_N) = \mathbf{x} \in \mathcal{X}^N.$$

Statt aus dieser einen Punkt- oder Intervall-Schätzer zu extrahieren, wird im vorliegenden Abschnitt „lediglich“ eine Beschreibung dieser Stichprobe abgeleitet, sei es grafisch oder durch Rechnung.

Die Darstellung beschränkt sich auf wenige Methoden. Bei Interesse findet sich Ausführlicheres in [Hen17], [Bo94] und einer Vielzahl weiterer Literatur.

- Der *empirische Erwartungswert* entspricht dem *arithmetische Mittel* einer Stichprobe $x = (x_1, \dots, x_N)$ und ist definiert als:

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

- **Bemerkung:**

- Der Mittelwert scheint ein naheliegender Schätzer für den Erwartungswert zu sein. Das ergab sich beispielsweise bei der ML-Schätzung des Erwartungswertes einer Normalverteilung.
- Beachte: Grundsätzlich ist das arithmetische Mittel aber nur eine Berechnungsvorschrift. Ob diese ein guter Schätzer ist, hängt von dem verwendeten statistischen Modell ab.

- Die *empirische Varianz* einer Stichprobe $x = (x_1, \dots, x_N)$ ist definiert als:

$$s^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

- Daraus entsteht die *empirische Standardabweichung*

$$s = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2}$$

- **Bemerkung:**

- Oben definierte Größe s^2 ist beispielsweise ein erwartungstreuer Schätzer für die Varianz einer Normalverteilung bei unbekanntem Erwartungswert.
- Ist der Erwartungswert bekannt, so entsteht ein erwartungstreuer Schätzer, falls man den Vorfaktor zu $1/N$ setzt.

Definition

Gegeben ist eine iid Beobachtung bzw. einfache Stichprobe

$$\mathbf{X} = (X_1, \dots, X_N) = (x_1, \dots, x_N) = \mathbf{x} \in \mathcal{X}^N.$$

Aus dieser entsteht die *geordnete Stichprobe* bzw. *Ordnungsstatistik* durch Sortieren, sodass:

$$(x_{(1)}, \dots, x_{(N)}) \quad \text{mit} \quad x_{(1)} \leq \dots \leq x_{(N)}$$

■ **Beispiel:** (... kennen Sie noch, oder? ...)

- Die Studiendauern an einer Hochschule werde über eine Zufallsvariable $X \in \mathbb{N}$ beschrieben.⁴⁵
- Die Abschlussdauern $X_i, i \in [1 : 10]$ von $N = 10$ Studierenden seien

$$\mathbf{x} = (x_1, \dots, x_{10}) = (11, 10, 7, 51, 8, 9, 12, 11, 10, 9)$$

- Die sortierte Stichprobe lautet dann:

$$\begin{aligned} (x_{(1)}, x_{(2)}, \dots, x_{(10)}) &= (x_3, x_5, x_6, x_{10}, x_2, x_9, x_1, x_8, x_4) \\ &= (7, 8, 9, 9, 10, 10, 11, 11, 12, 51) \end{aligned}$$

⁴⁵ ... die Studiendauern seien hier nicht durch die PO begrenzt und die Semesterzahl nur ganzzahlig...

- **Beispiel/Übung:** (nachdem Sie es selbst versucht haben: siehe Skript für $X_{(1)}$, $X_{(N)}$)
 - Gegeben ist eine einfache Stichprobe $\mathbf{X}$.
 - Welche Verteilung haben $X_{(1)}$, $X_{(N)}$ und allgemein $X_{(i)}$ (etwas schwieriger)?

- Der *empirische Median* einer Stichprobe $x = (x_1, \dots, x_N)$ entsteht aus einer geordneten Stichprobe $(x_{(1)}, \dots, x_{(N)})$ durch:

$$x_{1/2} = \begin{cases} x_{(\frac{N+1}{2})}, & N \text{ ungerade} \\ \frac{1}{2} \left(x_{(\frac{N}{2})} + x_{(\frac{N}{2}+1)} \right), & N \text{ gerade} \end{cases}$$

- Das *p-Quantil* einer Stichprobe $x = (x_1, \dots, x_N)$ ergibt sich als Verallgemeinerung des Median zu

$$x_p = \begin{cases} x_{(\lfloor Np+1 \rfloor)}, & Np \notin \mathbb{N} \\ \frac{1}{2} \left(x_{(Np)} + x_{(Np+1)} \right), & Np \in \mathbb{N} \end{cases}$$

- Der *Quartilsabstand* einer Stichprobe $x = (x_1, \dots, x_N)$ lautet:

$$x_{3/4} - x_{1/4}$$

- **Bemerkung:**

- Der Quartilsabstand kann ebenfalls als ein Maß für die Breite der Streuung einer Verteilung dienen.
- Im Gegensatz zur empirischen Varianz ist der Quartilsabstand robuster gegen Ausreißer.

■ **Beispiel:** (... kennen Sie noch, oder? ...)

■ An zwei Hochschulen HS_1 und HS_2 machen $N = 10$ Studierende ihren Abschluss mit der Dauer:⁴⁶

HS_1 : 7, 8, 9, 9, 10, 10, 11, 11, 12, 51

HS_2 : 2, 7, 8, 9, 9, 10, 10, 11, 11, 12

■ Man rechnet:

	$\bar{x}$	$x_{1/2}$	s^2	s	$x_{3/4} - x_{1/4}$
HS_1	13,8	10	173,07	13,16	2
HS_1 (numpy)	13,8	10	155,76	12,48	2
HS_2	8,9	9,5	8,1	2,85	3
HS_2 (numpy)	8,9	9,5	7,29	2,7	2,5

⁴⁶... die Studiendauern seien hier nicht durch die PO begrenzt und die Semesterzahl nur ganzzahlig...

- Das *Histogramm* kennen Sie bereits...
- Hierzu teilt man eine Stichprobe $x = (x_1, \dots, x_N)$ in *Klassen* ein.
 - Setze $a < x_{(1)}$ und $b > x_{(N)}$.
 - Lege eine Anzahl K von Klassen fest.⁴⁷
 - Definiere eine Unterteilung

$$[a, b) = [a_1, a_2) \cup [a_2, a_3) \cup \dots \cup [a_K, a_{K+1})$$

- Bestimme die relativen Häufigkeiten in jeder Klasse:


$$H_k = \frac{1}{N} \sum_{i=1}^N \mathbb{1}\{a_k \leq x_i < a_{k+1}\}, \quad k \in [1 : K]$$

und zeichne diese auf.

⁴⁷Laut [Hen17] kann hier $K \approx \sqrt{N}$ als „Faustregel“ dienen.

■ Beispiel:⁴⁸ 49


■ Größe und Gewicht in 3 424 Datensätzen



⁴⁸ Datei: size_weight.ipynb

⁴⁹ Datensatz aus: <http://wikis.fu-berlin.de/pages/viewpage.action?pageId=696156185>;
„[...] Pool der Befragten repräsentativ für die Bevölkerung in Deutschland. [...]“

- Der *Boxplot* „[...] dient dem schnellen Vergleich verschiedener Stichproben [...]“ [Hen17].
- Hierzu stellt man die Stichprobe $x = (x_1, \dots, x_N)$ grafisch⁵⁰ mit verschiedenen Quantile dar





⁵⁰Darstellung gemäß [Hen17]

⁵¹Praktisch am Beispiel des unteren Whiskers: Berechne $x_{1/4} - \frac{3}{2}(x_{3/4} - x_{1/4})$ und suche die nächste Beobachtung Richtung Mitte.

■ Beispiel:⁵² 53

■ Boxplot des Gewichts in 3 424 Datensätzen



⁵² Datei: size_weight.ipynb

⁵³ Datensatz aus: <http://wikis.fu-berlin.de/pages/viewpage.action?pageId=696156185>;


„[...] Pool der Befragten repräsentativ für die Bevölkerung in Deutschland. [...]“

- Falls die Länge der iid-Stichprobe $x = (x_1, \dots, x_N)$ „sehr groß“ ist, kann der zentrale Grenzwertsatz Anwendung finden. Dann ist *bei Mittelung* approximativ:

$$\bar{X}_N \sim \mathcal{N}\left(\bar{x}, \frac{s^2}{N}\right)$$



und somit:

$$P\left(-k \leq \frac{\bar{X}_N - \bar{x}}{\sqrt{\frac{s^2}{N}}} \leq k\right) \approx \begin{cases} 0,68, & k = 1 \\ 0,955, & k = 2 \\ 0,997, & k = 3 \end{cases}$$



■ Beispiel:⁵⁴

■ Boxplot und Gauß-Approximation bei Bestimmung von Fehlerraten



⁵⁴ Datei: sim_ber.ipynb

- Die *empirische Verteilungsfunktion* stellt basierend auf einer Beobachtung deren Verteilungsfunktion dar:

$$F_N(\xi) := \frac{1}{N} \sum_{n=1}^N \mathbb{1}\{x_n \leq \xi\}$$

- **Beachte:** Eine eventuelle Sortierung der Stichprobe ändert nichts an der Form der empirischen Verteilungsfunktion, erleichtert aber evtl. höchstens die Summation/Implementierung.

- Die *empirische Verteilungsfunktion* stellt basierend auf einer Beobachtung deren Verteilungsfunktion dar durch



$$F_N(\xi) := \frac{1}{N} \sum_{n=1}^N \mathbb{1}\{x_n \leq \xi\}$$

■ Bemerkungen:

- N sehr groß $\implies$ man kann (vielleicht) hoffen, dass die empirische Verteilungsfunktion sich der wahren Verteilungsfunktion annähert. Dies hatten wir im Rahmen des ZGWS als Konvergenz in Verteilung bezeichnet.
- Tatsächlich kann die Abweichung zwischen empirischer Verteilungsfunktion und angenommener Verteilungsfunktion als Kenngröße für statistische Tests dienen, vgl. Abschnitt ??; dies erledigt beispielsweise der Kolmogorow-Smirnow-Test.

■ Beispiel:⁵⁵

■ Empirische Verteilungsfunktion und wahre Verteilungsfunktion



⁵⁵ Datei: empirical_parameters.ipynb

- Neben der Punktschätzung und den Konfidenzintervallen, die einen Schätzwert oder -intervall für einen Parameter $\vartheta \in \Theta$ erzeugen, ergeben sich oft Situationen, in denen man zwischen zwei Optionen (etwa für ϑ) wählen muss.
- Hierbei gilt es zu entscheiden, *von welcher der beiden „Verteilung-Optionen“ eine Stichprobe am plausibelsten erzeugt wurde.*
- Das ist der *große Unterschied* zu den bisherigen Methoden: Wir wollen *nicht einen Parameter schätzen* (weder Punkt-, noch Intervallschätzung), sondern *zwischen zwei Verteilungsfamilien unterscheiden.*
- **Beispiel:** Ist ein neues Medikament wirkungsvoller als ein bereits existierendes Medikament?

- Der Ansatz in einem statistischen Modell $(\mathcal{X}, (P_{\vartheta})_{\vartheta \in \Theta})$ lautet⁵⁶

$$\Theta = \Theta_0 + \Theta_1$$

mit der *Hypothese* (auch: *Nullhypothese*) H_0 und der *Alternative* (auch: *Alternativhypothese*) H_1 :

$$H_0 : \vartheta \in \Theta_0$$

$$H_1 : \vartheta \in \Theta_1$$

- Die Hypothese bzw. Alternative heißen *einfach*, falls $|\Theta_i| = 1$, d.h. nur ein Parameter „zur Auswahl steht“.
- Ein Test heißt *einseitig*, falls $H_0 : \vartheta \leq a$ und $H_1 : \vartheta > a$ und *zweiseitig*, falls $H_0 : \vartheta = a$ und $H_1 : \vartheta \neq a$. [Hen17]

⁵⁶**Erinnerung:** Die Schreibweise $A + B$ für Mengen A, B steht stellvertretend für die Vereinigung $A \cup B$ im Fall $A \cap B = \emptyset$.

■ Beispiele:

■ Vorhersage eines Münzwurfs

- Eine Person behauptet das Ergebnis eines Münzwurfs vorhersagen zu können.
- Um dies zu überprüfen wählt man $\Theta = [1/2, 1]$, damit $\Theta_0 = \{1/2\}$, $\Theta_1 = (1/2, 1]$ und

$$H_0 : \vartheta = \frac{1}{2} \hat{=} \text{„Person rät“}$$

$$H_1 : \vartheta > \frac{1}{2} \hat{=} \text{„Person kann etwas vorhersagen“}$$

- Überlegenheit einer neuen medizinischen Behandlung gegenüber einer existierenden Behandlung [Hen17]. Der Parameter ϑ beschreibt dann die Erfolgswahrscheinlichkeit der Therapie.

- Zur Beschreibung der Entscheidung definiert man

$$\mathcal{K}_0 := \{x \in \mathcal{X}^N : \text{Entscheidung für } H_0\}$$

$$\mathcal{K}_1 := \{x \in \mathcal{X}^N : \text{Entscheidung für } H_1\}$$

$$\mathcal{X}^N = \mathcal{K}_0 + \mathcal{K}_1$$

als diejenigen Beobachtungen, bei deren Beobachtungen man sich für die Hypothese bzw. die Alternative entscheidet. Die Menge $\mathcal{K}_1$ heißt *kritischer Bereich* des Tests, der Bereich $\mathcal{K}_0$ der *Annahmebereich*. In $\mathcal{K}_0$ „wird H_0 angenommen“.

Beachte: Diese Formulierung ist mathematisch nicht ganz korrekt: Wie wir später sehen werden, steht hier die Beobachtung x nur nicht im Widerspruch zu H_0 .

■ Die Wahrscheinlichkeiten für Entscheidung und Realität und deren abkürzenden Schreibweise lauten:

$$P(H_0|H_0) := P_{\vartheta}(\mathbf{X} \in \mathcal{K}_0 | \vartheta \in \Theta_0) \rightarrow \text{juhuu!}$$

$$P(H_1|H_0) := P_{\vartheta}(\mathbf{X} \in \mathcal{K}_1 | \vartheta \in \Theta_0) \rightarrow \text{Fehler 1. Art!}$$

$$P(H_0|H_1) := P_{\vartheta}(\mathbf{X} \in \mathcal{K}_0 | \vartheta \in \Theta_1) \rightarrow \text{Fehler 2. Art!}$$

$$P(H_1|H_1) := P_{\vartheta}(\mathbf{X} \in \mathcal{K}_1 | \vartheta \in \Theta_1) \rightarrow \text{juhuu!}$$

- Die Wahrscheinlichkeiten lassen sich in einer Tabelle zusammenfassen:

		Realität:	
		$\vartheta \in \Theta_0$	$\vartheta \in \Theta_1$
Entscheidung:	H_0	$P(H_0 H_0)$ korrekt	$P(H_0 H_1)$ Fehler 2. Art
	H_1	$P(H_1 H_0)$ Fehler 1. Art	$P(H_1 H_1)$ korrekt

- Meist/oft ist die Entscheidung für Hypothese bzw. Alternative nicht symmetrisch, sondern man begrenzt die Wahrscheinlichkeit für einen Fehler 1. Art $P(H_1|H_0)$.
→ „Bleibe lieber bei H_0 , falls H_1 nicht eindeutig besser ist.“
- Tiefer gehende Diskussionen und Erläuterungen zu dieser Wahl und deren Konsequenzen finden sich in [Hen17].

- Die *Gütefunktion* eines Tests beschreibt die Wahrscheinlichkeit des kritischen Bereiches $\mathcal{K}_1$ unter ϑ und lautet:

$$g : \begin{cases} \Theta \rightarrow [0, 1] \\ \vartheta \mapsto P_{\vartheta}(\mathbf{X} \in \mathcal{K}_1) \end{cases}$$

- Ideal wäre es nun, wenn $g(\vartheta) = 0$ für $\vartheta \in \Theta_0$ und gleichzeitig (!) $g(\vartheta) = 1$ für $\vartheta \in \Theta_1$ wäre.
- Jede Forderung für sich genommen, wäre etwa durch $\mathcal{K}_1 = \emptyset$ bzw. $\mathcal{K}_1 = \mathcal{X}^N$ zu erreichen. Dies ergäbe allerdings sehr große Fehler 2. Art bzw. 1. Art.

- Die Beschränkung der Wahrscheinlichkeit eines Fehlers 1. Art lautet:

$$g(\vartheta) \leq \alpha, \vartheta \in \Theta_0$$

In diesem Fall nennt man den Test einen *Test zum Niveau α* .

- Das Niveau eines Tests begrenzt also die Wahrscheinlichkeit dafür, sich fälschlicherweise für H_1 zu entscheiden, auf maximal α .

■ Illustration/Diskussion:

■ Beispiel: (Binomialverteilung; [Hen95])

- Gegeben ist ein Bernoulli-Modell mit $\mathcal{X} = \{0, 1\}$ und unbekannter Trefferwahrscheinlichkeit $\vartheta := P(X = 1)$.
- Bei N -facher Beobachtung folgt somit⁵⁷ $\mathcal{X}^N = \{0, 1\}^N$ und

$$P_{\vartheta}(\mathbf{X} = \mathbf{x}) = \vartheta^n (1 - \vartheta)^{N-n}; \quad n := \sum_{i=1}^N x_i$$

- Möchte man die Hypothese $H_0 : \vartheta = \frac{1}{2}$ gegen die Alternative $H_1 : \vartheta > \frac{1}{2}$ testen, so entspricht die Alternative der Tatsache, dass die Trefferwahrscheinlichkeit höher als 50 % ist.
- Anschaulich würde man die Hypothese verwerfen („kein reiner Zufall“), wenn die Trefferanzahl zu hoch ist, etwa mit $K \in [0 : N]$:

$$\mathcal{K}_1 := \left\{ \mathbf{x} \in \mathcal{X}^N : \sum_{i=1}^N x_i \geq K \right\}$$

⁵⁷ ...siehe auch entsprechende Rechnungen im Abschnitt „Punktschätzer“ ...

■ **Beispiel:** (Binomialverteilung; [Hen95]) (ctd.)

■ Zählt man die Treffer in der Bernoulli-Kette, so folgt eine Zufallsvariable

$$S_N := \sum_{i=1}^N X_i \sim \text{Bin}(N, \vartheta)$$

und damit:

$$g(\vartheta) = P_{\vartheta}(\mathcal{K}_1) = \sum_{n=K}^N \binom{N}{n} \vartheta^n (1 - \vartheta)^{N-n}$$

■ Für einen Test zum Niveau α muss damit gelten (beachte $\Theta_0 = \{\frac{1}{2}\}$):

$$g(\vartheta_0) = g\left(\frac{1}{2}\right) = \left(\frac{1}{2}\right)^N \sum_{n=K}^N \binom{N}{n} \stackrel{!}{\leq} \alpha$$

■ **Beispiel:** (Binomialverteilung; [Hen95]) (ctd.)

■ **Erinnerung:** Für einen Test zum Niveau α muss gelten:

$$\left(\frac{1}{2}\right)^N \sum_{n=K}^N \binom{N}{n} \stackrel{!}{\leq} \alpha$$

■ Für $N = 10$ und $\alpha = 0,05$ ergibt sich:

$$\sum_{n=K}^N \binom{N}{n} \stackrel{!}{\leq} 0,05 \cdot 2^{10} = 51,2$$

Einsetzen liefert:

K	$\sum_{n=K}^{10} \binom{10}{n}$
10	$\binom{10}{10} = 1$
9	$\binom{10}{9} + 1 = 11$
8	$\binom{10}{8} + 11 = 45 + 11 = 56 > 51,2$

■ **Beispiel:** (Binomialverteilung; [Hen95]) (ctd.)

- Damit muss man mindestens 9 Treffer fordern, damit die Wahrscheinlichkeit dafür, *zufällig derart viele Treffer zu erzielen*, höchstens 0,05 beträgt.
- Das tatsächliche Niveau des Tests ist dann:

$$g\left(\frac{1}{2}\right) = \left(\frac{1}{2}\right)^{10} \sum_{n=9}^{10} \binom{10}{n} = \frac{1 + 11}{1024} = \frac{12}{1024} \approx 0,011,$$

also „viel kleiner als gefordert“.

- Den Wert 8 kann man aber nicht hinzunehmen, da sonst der Fehler 1. Art zu groß wäre:

$$g\left(\frac{1}{2}\right) = \left(\frac{1}{2}\right)^{10} \sum_{n=8}^{10} \binom{10}{n} = \frac{1 + 10 + 45}{1024} = \frac{56}{1024} \approx 0,055,$$

■ **Beispiel:**⁵⁸ (Binomialverteilung; [Hen95]) (ctd.)

- Simulationen mit veränderlichem Niveau α
- „Spielen“ mit Parametern



⁵⁸ **Datei:** test_binomial.ipynb

■ Bemerkungen:

- Im Binomial-Beispiel war das tatsächliche Niveau des Tests mit $g\left(\frac{1}{2}\right) \approx 0,011$ deutlich kleiner als die geforderten 0,05.
- Den Wert 8 konnte man aber nicht hinzunehmen, da sonst der Fehler 1. Art zu groß wäre.
- In der Terminologie der Testtheorie hat man „das Niveau α nicht ausgeschöpft“.
- Eine Lösung bestünde in der Verwendung „randomisierter Tests“, wofür allerdings auf weiterführende Literatur, z.B. [Hen17], verwiesen wird.

■ Etwas Diskussion ist sicherlich hilfreich...

■ Etwas Diskussion ist sicherlich hilfreich...

- Im Folgenden wird kurz der *Chi-Quadrat-Anpassungstest* skizziert, der weitreichende Anwendungen in praktischen Fragestellungen besitzt.
- Für tiefer gehende Betrachtung und weitere Testverfahren sei auf die Literatur verwiesen.
- Die folgenden Betrachtungen folgen [Bo94, S. 102-108].

- Gegeben ist eine iid Stichprobe $(X_1, \dots, X_N) = (x_1, \dots, x_N)$.
- Betrachtet wird eine Polynomialverteilung mit:

$$A_i \in \mathcal{B}, \quad P(A_i) > 0, \quad i \in [1 : r], \quad \sum_{i=1}^r A_i = \Omega$$

- Die zu prüfende *Hypothese* und *Alternative* sind:

$$H_0 : P(A_i) = p_i, \quad \text{für alle } i \in [1 : r]$$

$$H_1 : P(A_i) \neq p_i, \quad \text{für mind. ein } i \in [1 : r]$$

- Gegeben ist eine iid Stichprobe $(X_1, \dots, X_N) = (x_1, \dots, x_N)$.
- Definiere die Anzahl der „Treffer“ für A_i als

$$Y_i := \sum_{k=1}^N \mathbb{1}\{X_k \in A_i\}$$

Falls die Hypothese H_0 zutrifft, ist Y_i binomialverteilt mit $Y_i \sim \text{Bin}(N, p_i)$ und somit ist $\mathbb{E}(Y_i) = Np_i$ und $\mathbb{V}(Y_i) = Np_i(1 - p_i)$.

- Definiere die Zufallsvariable:

$$\frac{Y_i - Np_i}{\sqrt{Np_i}} \stackrel{(a)}{\sim} \mathcal{N}(0, 1 - p_i), \quad i \in [1 : r],$$

wobei sich (a) aus dem zentralen Grenzwertsatz ergibt, falls die Hypothese H_0 zutrifft und die Beobachtungslänge N hinreichend groß ist.

- **Erinnerung:** Unter H_0 gilt für große N :

$$\frac{Y_i - Np_i}{\sqrt{Np_i}} \stackrel{(a)}{\sim} \mathcal{N}(0, 1 - p_i), \quad i \in [1 : r],$$

- Daraus definiert man die *Chi-Quadrat-Testgröße*

$$T := \sum_{i=1}^r \frac{(Y_i - Np_i)^2}{Np_i},$$

welche die „[...] Größe der Abweichung zwischen den beobachteten Trefferanzahlen Y_i und den unter H_0 erwarteten Anzahlen Np_i in einer ganz bestimmten Weise misst.“ [Hen95]

■ Für

$$T := \sum_{i=1}^r \frac{(Y_i - Np_i)^2}{Np_i}$$

gilt:

$$E_{\vartheta_0}(T) = r - 1$$

$$\lim_{N \rightarrow \infty} V_{\vartheta_0}(T) = 2(r - 1)$$

- Falls $Np_i \geq 5$ für alle $i \in [1 : r]$ ist, so besitzt T *approximativ* eine χ^2 -Verteilung mit $r - 1$ Freiheitsgraden, wobei die Verteilungsfunktion einer χ^2 -Verteilung mit k Freiheitsgraden gegeben ist durch

$$F_k(t) = \frac{1}{2^{\frac{k}{2}} \Gamma\left(\frac{k}{2}\right)} \int_0^t u^{\frac{k}{2}-1} e^{-\frac{u}{2}} \, du$$

und die Gamma-Funktion $\Gamma(\ell + 1) = \int_0^\infty t^\ell e^{-t} \, dt$ eine Verallgemeinerung der Fakultät darstellt.

- Damit folgt im Falle der Gültigkeit der Hypothese:

$$P\left(\sum_{i=1}^r \frac{(Y_i - Np_i)^2}{Np_i} > t\right) \approx P(\chi_{r-1}^2 > t)$$

- Der *Chi-Quadrat-Test* berechnet die Testgröße:

$$t := \sum_{i=1}^r \frac{(y_i - Np_i)^2}{Np_i}$$

Anschaulich: „Falls H_0 korrekt ist, sollten kleine Werte für T wahrscheinlicher und große Werte unwahrscheinlich sein; ist H_0 nicht korrekt, sind große Werte wahrscheinlicher“.

- **Erinnerung:** Bei Niveau α eines Tests soll gelten: $P_{\vartheta}(\mathbf{X} \in \mathcal{K}_1) \leq \alpha$ für $\vartheta \in \Theta_0$

■ Testablauf:

- Festlegung des Niveaus α .
- Prüfen von $Np_i \geq 5, i \in [1 : r]$
- Berechnen der (auf den Beobachtungen basierenden) Größe⁵⁹

$$t := \sum_{i=1}^r \frac{(y_i - Np_i)^2}{Np_i}.$$

- Ablesen des $1 - \alpha$ Quantils⁶⁰ $\chi_{r-1, 1-\alpha}^2$ einer Chi-Quadrat-Verteilung aus einer Tabelle (oder dem Rechner).
- Falls $t > \chi_{r-1, 1-\alpha}^2$, dann lehne die Hypothese H_0 auf dem Niveau α ab; ansonsten wird die Hypothese nicht abgelehnt.⁶¹

⁵⁹**Erinnerung:** Die Beobachtungen $(X_1, \dots, X_N)$ werden verwendet um die Trefferhäufigkeiten $Y_i := \sum_{k=1}^N \mathbb{1}\{X_k \in A_i\}, i \in [1 : r]$ zu berechnen.

⁶⁰Suche den Wert, bei dem $\chi_{r-1, 1-\alpha}^2$ höchstens mit Wahrscheinlichkeit α größer ist.

⁶¹Anschaulich: t ist so groß, dass dies unter H_0 nur mit Wahrscheinlichkeit $\leq \alpha$ auftreten sollte.

■ Beispiel: ⁶² ⁶³ (Würfelwurf)



- Es wurden $N = 120$ zufällige Zahlen aus $\{1, \dots, 6\}$ erzeugt⁶⁴ und folgende absolute Häufigkeiten beobachtet:

k	1	2	3	4	5	6
$h_N(k)$	30	25	18	10	22	15

- **Frage:** Sind das jeweils Beobachtungen, die einen „fairen“ Würfel repräsentieren und zu welchem Niveau?
- **Antwort (und mehr):** Siehe **Datei:** test_chi_square.ipynb

⁶² **Datei:** test_chi_square.ipynb

⁶³ Aus [Bo94]

⁶⁴ ... und damit eine Sequenz von Würfelwürfen simuliert...

■ Beispiel: ⁶⁵ ⁶⁶ (Würfelwurf)

■ **Antwort (und mehr):** Siehe **Datei:** test_chi_square.ipynb

■ Einige exemplarische Ergebnisse:

	t	$\chi_{r-1,1-\alpha}^2$	Entscheidung	Terminologie
$\alpha = 0,01$	12,90	15,07	H_0	„ H_0 nicht bei Niveau α abgelehnt“
$\alpha = 0,05$	12,90	11,07	H_1	„ H_0 bei Niveau α abgelehnt“
$\alpha = 0,1$	12,90	9,24	H_1	„ H_0 bei Niveau α abgelehnt“

■ Achtung:

■ Größere $\alpha = P(H_1|H_0) \implies$ kleinere $\chi_{r-1,1-\alpha}^2 \implies$ eher Entscheidung H_1

■ Kleinere $\alpha = P(H_1|H_0) \implies$ größere $\chi_{r-1,1-\alpha}^2 \implies$ eher Entscheidung H_0

⁶⁵ **Datei:** test_chi_square.ipynb

⁶⁶ Aus [Bo94]



■ **Ergänzung:** (Test auf beliebige Verteilungsfunktion [Bo94])

- Um eine Verteilung auf eine beliebige, auch stetige Verteilungsfunktion $F(x)$ zu testen, kann man den Chi-Quadrat-Test folgendermaßen adaptieren:

- Unterteile gemäß

$$\begin{aligned}\mathbb{R} &= (-\infty, a_1] + (a_1, a_2] + \cdots + (a_{r-2}, a_{r-1}] + (a_{r-1}, \infty) \\ &= R_1 \quad \quad + R_2 \quad \quad + \cdots + R_{r-1} \quad \quad + R_r\end{aligned}$$

- Setze

$$p_i := P(Y \in R_i), \quad i \in [1 : r]$$

und verwende den für die Polynomialverteilung diskutierten Test.

■ **Ergänzung:** (Test auf Unabhängigkeit [Hen95])

- Mittels des Chi-Quadrat-Tests können Zufallsvariablen X, Y auf Unabhängigkeit getestet werden.
- Hypothese und Alternative sind damit:

$$H_0 : P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j)$$

$$H_1 : P(X = x_i, Y = y_j) \neq P(X = x_i) \cdot P(Y = y_j) \text{ für mindestens ein Paar } (x_i, y_j)$$

- Gegeben sind Beobachtungen $(X_n, Y_n) = (x_n, y_n)$, $n \in [1 : N]$ mit diskreten Wertemengen $\mathcal{X}, \mathcal{Y}$, die als endlich angenommen werden, d.h. $|\mathcal{X}| = K_{\mathcal{X}}, |\mathcal{Y}| = K_{\mathcal{Y}}$
- Bestimme über relative Häufigkeiten Schätzwerte für Verbund- und Randverteilungen
- Vergleiche mit einer Chi-Quadrat-Kenngröße die Abweichungen zwischen diesen beiden Verteilungen
- Wenn die Abweichungen „klein“ sind, kann zu einem Niveau α von einer Unabhängigkeit der beiden Zufallsgrößen ausgegangen werden.

■ **Ergänzung:** (Test auf Unabhängigkeit [Hen95])

- Berechne Auftretenshäufigkeiten für Paare und Einzelwerte:

$$Z_{ij} = \sum_{n=1}^N \mathbb{1}\{X_n = x_i, Y_n = y_j\}$$

$$Z_{i\bullet} = \sum_{j=1}^{K_Y} Z_{ij}$$

$$Z_{\bullet j} = \sum_{i=1}^{K_X} Z_{ij}$$

Deren Darstellung in einer Tabelle nennt man *Kontingenztafel*. (siehe späteres Beispiel)

- Bei Gültigkeit von H_0 ist approximativ:

$$\frac{Z_{ij}}{N} \approx P_{(X,Y)}(i,j) \stackrel{?!}{=} P_X(i) \cdot P_Y(j) \approx \frac{Z_{i\bullet}}{N} \cdot \frac{Z_{\bullet j}}{N}$$

■ Ergänzung: (Test auf Unabhängigkeit [Hen95])

- Berechne aus den Häufigkeiten die Testgröße

$$t := \sum_{i=1}^{K_X} \sum_{j=1}^{K_Y} \frac{(Z_{ij} - \frac{1}{N} Z_{i\bullet} Z_{\bullet j})^2}{\frac{1}{N} Z_{i\bullet} Z_{\bullet j}}.$$

- Bestimme das Quantil

$$\chi^2_{(K_X-1) \cdot (K_Y-1), 1-\alpha}.$$

- Vergleiche die Testgröße mit dem Quantil und entscheide⁶⁷:

$$t > \chi^2_{(K_X-1) \cdot (K_Y-1), 1-\alpha} \implies H_0 \text{ wird auf dem Niveau } \alpha \text{ abgelehnt}$$

$$t < \chi^2_{(K_X-1) \cdot (K_Y-1), 1-\alpha} \implies H_0 \text{ wird nicht auf dem Niveau } \alpha \text{ abgelehnt}$$

„ H_1 wird auf dem Niveau α akzeptiert“

⁶⁷Wir wissen natürlich, dass formal nicht H_1 akzeptiert, sondern H_0 nicht abgelehnt wird...

■ Beispiel: ⁶⁸ (Unabhängigkeit) (immer noch aus [Hen95])



- Analysiert wird die Abhängigkeit von Blütenfarbe und Blätterbeschaffenheit einer Pflanze.
- Es ergaben sich die folgenden Häufigkeiten, zusammengefasst in einer Kontingenztafel:

		Farbe:		Σ
		weiß	rosa	
Blätter:	glatt	12	4	16
	rau	9	23	32
Σ		21	27	48

- Für diesen Fall ergibt sich $t = 9,52$ und $\chi^2_{(2-1) \cdot (2-1), 1-0,05} = \chi^2_{1,0,95} = 3,84$.
- Damit ist $t > \chi^2_{1,0,95}$ und die Hypothese der Unabhängigkeit von Farbe und Beschaffenheit der Blätter wird auf einem 5% Niveau abgelehnt.

⁶⁸ Datei: test_chi_square.ipynb

■ Beachte:

- Der Chi-Quadrat-Test basiert auf der Annahme einer Chi-Quadrat-Verteilung.
- Diese wiederum fußt auf Anwendung des ZGWS, um

$$Y_i \sim \mathcal{N}(0, 1 - p_i)$$

annehmen zu können.

- Daher ist der Test lediglich für große Stichprobenumfänge anwendbar (siehe Kriterium $Np_i \geq 5$).
- Die Berechnungen zum statistischen Niveau gelten daher oft nur asymptotisch.

■ Bemerkung:

- Bisher wurde „nur“ ein Test auf Orakel-Fähigkeit (einseitiger Binomialtest) und der Chi-Quadrat-Test vorgestellt.
- In Ihrer späteren Anwendung können Ihnen evtl. viele viele weitere Tests begegnen, z.B. der Kolmogorow-Smirnow-Test zur Überprüfung einer Verteilungsannahme. (siehe Skript)
- Tests können bzgl. vieler verschiedener Zielsetzungen durchgeführt werden⁶⁹
 - Tests auf Parameter wie Mittelwert, Median, Varianz, ...
 - Tests auf Unkorreliertheit oder Unabhängigkeit
 - Tests auf Verteilungen einer Grundgesamtheit; insbesondere als Teil eines „distribution fitting“

⁶⁹ Auflistung gemäß https://de.wikipedia.org/wiki/Statistischer_Test; abgerufen am 27.9.2024

- Das Vorgehen bei Durchführen eines Hypothesentests ist hierbei immer ähnlich:
 - Eine Hypothese H_0 wird gegen eine Alternative H_1 geprüft
 - Das Niveau des Tests (=Wahrscheinlichkeit für den Fehler 1. Art $P(H_1|H_0)$) wird auf α begrenzt
 - „Magische WT-Berechnungen oder -Approximationen“ liefern eine Testgröße sowieso ein Vergleichsquantil
 - Je nach Testgröße $\leq$ Vergleichsquantil wird die Hypothese abgelehnt oder eben nicht

- *Alle in diesem Kapitel dargestellten Methoden basieren auf zufälligen Beobachtungen!* 
- Damit sind alle Schlussfolgerungen mit Unsicherheit behaftet, was bei deren Interpretation berücksichtigt werden sollte.
- *Zudem ist meist vorausgesetzt, dass die Beobachtungen unabhängig und repräsentativ sind. Das muss sichergestellt sein...!* 

- **Beispiele:**
 - (Repräsentative?) Wahlumfrage per Festnetztelefon um 11:00 Uhr?!
 - Schätzung des Raucheranteils durch Umfrage in einem Laufverein?!
 - Schätzung der Altersstruktur in der Bevölkerung durch Beobachtungen in unserem WT-Hörsaal?!
 - (hier kann Ihr Beispiel stehen...)

- Die Angabe von (quadratischen) Schätzfehlern, Konfidenzintervallen, Niveaus oder anderen Zuverlässigkeitsinformationen, etwa in Boxplots, trägt dem Rechnung.
- Für „eigene quick-and-dirty“ Monte-Carlo-Simulationen wird man das oft aus Aufwandsgründen nicht machen, bei „Wichtigerem“ (was das auch sein mag: Bachelorarbeit, Masterarbeit, Paper, ...) ggf. schon.

- Die folgende Aufstellung fasst die zentralen Punkte zusammen.
- Es wird aufgezeigt, welche Punkte nach Bearbeitung des Kapitels klar sein sollten.
- **Hinweise:**
 - Die Auflistung ist nicht vollständig, sondern führt die wichtigsten Aussagen auf; nicht erwähnte Inhalte sind dennoch bedeutsam.
 - Oft enthalten die Nachweise wichtige Ideen; diese also nicht vernachlässigen.
 - Stets versuchen, Gleichungen in Verbindung mit Interpretationen und Anwendungen zu sehen
 - Des weiteren sollten alle kleinen nützlichen Ergänzungen verstanden sein.
 - Es ist immer eine gute Idee, etwas Gelerntes im Rechner umzusetzen. Dies hilft beim Verständnis und schärft das Bewusstsein für mögliche Probleme.

Nach diesem Kapitel sollten als zentrale Punkte klar sein:

- Motivation zur Verwendung von Schätzern und „Unterschied zu bisherigen Kapiteln“
- Punktschätzer
 - Grundidee; Punktschätzer als Zufallsvariablen
 - Eigenschaften: Erwartungstreue, Konsistenz, quadratische Abweichung
 - ML-Schätzung und Likelihood-Funktion
 - Fisher-Information, Cramér-Rao-Ungleichung; effiziente Schätzer (was bedeutet das praktisch?)
 - MMSE-Ansatz

Nach diesem Kapitel sollten als zentrale Punkte klar sein:

- Konfidenzintervalle
 - Abgrenzung zur Punktschätzung
 - Was ist ein Konfidenzniveau; wofür sind Konfidenzintervalle gut?
- Deskriptive Statistik: Rechnerische und grafische Methoden
- Hypothesentests
 - Hypothese und Alternative
 - Kritischer Bereich
 - Niveau eines Tests
 - Chi-Quadrat-Test

- [Hen95] N. Henze, *Stochastik I – Einführung in die Wahrscheinlichkeitstheorie und Statistik*, Skript Universität Karlsruhe (TH), 1995
- [Hen17] N. Henze. *Stochastik für Einsteiger – Eine Einführung in die faszinierende Welt des Zufalls*, 11. Auflage, Springer, 2017
- [CT06] T. Cover, J. Thomas, *Elements of Information Theory*, Wiley, 2006
- [Kre91] U. Krengel, *Einführung in die Wahrscheinlichkeitstheorie und Statistik*, Vieweg, 1991
- [Bo94] K. Bosch, *Elementare Einführung in die angewandte Statistik*, Vieweg, 1994
- [Pap91] A. Papoulis, *Probability, Random Variables, and Stochastic Processes*, 3rd Ed., New York 1991: McGraw-Hill, Inc.
- [PJ19] F. Puente León, H. Jäkel, *Signale und Systeme*, De Gruyter, 2019